

مروری بر مدل‌های زبانی

سپهر کراچی

۱۴۰۶

فهرست مطالب

۲	آموزش (Training)	۱
۲	۱.۱ داده‌ها (Data)	۱.۱
۲	۱.۱.۱ پیش‌آموزش (Pre-Training)	۱.۱.۱
۲	۲.۱.۱ پس‌آموزش (Post-Training)	۲.۱.۱
۳	۲.۱ روش (Method)	۲.۱
۳	۱.۲.۱ پیش‌آموزش (Pre-Training)	۱.۲.۱
۳	۲.۲.۱ پس‌آموزش (Post-Training)	۲.۲.۱
۴	ساختار (Architecture)	۲
۴	۱.۲ کدگذاری موقعیت (Positional Encoding)	۱.۲
۴	۲.۲ بردارکننده (Tokenizer)	۲.۲
۵	۳.۲ شبکه عصبی (MLP)	۳.۲
۵	۴.۲ تابع فعالساز (Activation Function)	۴.۲
۶	۵.۲ نرمالسازی (Normalization)	۵.۲
۶	۶.۲ مکانیزم توجه (Attention)	۶.۲
۷	۷.۲ ساختار ترنسفورمر (Transformer)	۷.۲
۷	بهینه‌سازی (Optimization)	۳
۷	۱.۳ الگوریتم (Algorithm)	۱.۳
۸	۲.۳ تابع هزینه (Loss Function)	۲.۳
۸	تنظیم هایپرپارامتر (Hyperparameter Tuning)	۴
۹	قوانین مقیاس‌پذیری (Scaling Laws)	۵
۹	۱.۵ مقدمه	۱.۵
۹	۲.۵ اصلاح و توسعه قوانین مقیاس‌پذیری کلاسیک	۲.۵
۹	۳.۵ تاثیر معماری و شکل مدل (Model Shape & Architecture)	۳.۵
۱۰	۴.۵ قوانین مقیاس‌پذیری برای مدل‌های ترکیبی از خبرگان (MoE)	۴.۵
۱۰	۵.۵ نقش داده‌ها: کیفیت، ترکیب و چگالی	۵.۵
۱۱	۶.۵ فراتر از خطای مطلق: معیارهای نوین ارزیابی	۶.۵
۱۱	۷.۵ نتیجه‌گیری	۷.۵
۱۱	ارزیابی (Evaluation)	۶
۱۲	یادگیری تقویتی (Reinforcement Learning)	۷
۱۲	۱.۷ الگوریتم بهینه‌سازی تقریبی خطمشی (Proximal Policy Optimization - PPO)	۱.۷
۱۹	۲.۷ الگوریتم بهینه‌سازی نسبی خطمشی گروهی (Group Relative Policy Optimization - GRPO)	۲.۷
۲۴	۳.۷ الگوریتم بهینه‌سازی توالی گروهی خطمشی (Group Sequence Policy Optimization - GSPO)	۳.۷
	۴.۷ الگوریتم بهینه‌سازی خطمشی با برش مجزا و نمونه‌برداری پویا (Decoupled Clip and Dy-)	۴.۷
۳۱	نامی (namic Sampling Policy Optimization - DAPO)	۳۱
۳۷	۵.۷ الگوریتم بهینه‌سازی خطمشی تطبیقی نرم (Soft Adaptive Policy Optimization - SAPO)	۵.۷
۴۴	منابع	۸

۱ آموزش (Training)

۱.۱ داده‌ها (Data)

۱.۱.۱ پیش‌آموزش (Pre-Training)

- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda

۲.۱.۱ پس‌آموزش (Post-Training)

- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda

۲.۱ روش (Method)

۱.۲.۱ پیش‌آموزش (Pre-Training)

• sda

• sda

• sda

• sda

• sda

• sda

• sda

• sda

• sda

• sda

• sda

• sda

• sda

۲.۲.۱ پس‌آموزش (Post-Training)

• sda

• sda

• sda

• sda

• sda

• sda

• sda

• sda

• sda

• sda

• sda

• sda

• sda

۲ ساختار (Architecture)

۱.۲ کدگذاری موقعیت (Positional Encoding)

- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda

۲.۲ بردارکننده (Tokenizer)

- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda

۳.۲ شبکه عصبی (MLP)

- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda

۴.۲ تابع فعالساز (Activation Function)

- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda

۵.۲ نرمالسازی (Normalization)

- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda

۶.۲ مکانیزم توجه (Attention)

- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda

۷.۲ ساختار ترنسفورمر (Transformer)

- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda

۳ بهینه سازی (Optimization)

۱.۳ الگوریتم (Algorithm)

- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda

۲.۳ تابع هزینه (Loss Function)

- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda

۴ تنظیم هایپرپارامتر (Hyperparameter Tuning)

- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda

۵ قوانین مقیاس پذیری (Scaling Laws)

۱.۵ مقدمه

قوانین مقیاس‌پذیری (Scaling Laws) به عنوان یکی از ارکان اصلی در توسعه و درک مدل‌های زبانی بزرگ (LLMs) شناخته می‌شوند. این قوانین که در ابتدا توسط محققانی چون Kaplan و Hoffmann (قانون Chinchilla) مطرح شدند، نشان می‌دهند که عملکرد مدل‌ها با افزایش پارامترها، حجم داده‌ها و بودجه محاسباتی به صورت قابل پیش‌بینی بهبود می‌یابد. با این حال، تحقیقات اخیر نشان داده‌اند که قوانین کلاسیک دارای محدودیت‌هایی هستند؛ از جمله نادیده گرفتن هزینه‌های استنتاج (Inference)، تاثیر شکل معماری (Architecture Shape)، کیفیت داده‌ها و ساختارهای نوینی مانند «ترکیبی از خبرگان» (Mixture-of-Experts یا MoE). این بخش، با ترکیب و تحلیل ۱۹ مقاله علمی جدید، به بررسی ابعاد پنهان و توسعه‌یافته‌ی قوانین مقیاس‌پذیری می‌پردازد.

۲.۵ اصلاح و توسعه قوانین مقیاس‌پذیری کلاسیک

قوانین اولیه مانند Chinchilla فرض می‌کردند که نسبت بهینه داده به پارامتر (D/N) یک مقدار ثابت (حدود ۲۰) است. اما لی و همکاران [۱] با معرفی قانون Farseeer نشان می‌دهند که این نسبت ثابت نیست و با افزایش بودجه محاسباتی، نسبت بهینه D/N نیز افزایش می‌یابد. روش Farseeer با استفاده از برازش قطعه‌ای دیفرانسیلی (Differential Piecewise Fitting)، خطای برون‌یابی (Extrapolation Error) را نسبت به قانون Chinchilla تا ۴۳۳ درصد کاهش می‌دهد.

از سوی دیگر، چن و همکاران [۲] پدیده Sub-scaling (کاهش نرخ بهبود عملکرد) را بررسی می‌کنند. این پدیده زمانی رخ می‌دهد که مدل‌ها بیش از حد آموزش می‌بینند (Over-training) یا چگالی داده‌ها (افزونگی اطلاعات) بسیار بالا است. این مقاله یک قانون مقیاس‌پذیری زیر-بهینه (Sub-optimal) ارائه می‌دهد که نشان می‌دهد داده‌های با چگالی بالا منجر به رشد توانی (کاهش بازدهی نهایی) و داده‌های با چگالی پایین منجر به رشد خطی در عملکرد می‌شوند.

همچنین، مک‌لیش و همکاران [۳] با معرفی مجموعه Gemstones (شامل بیش از ۴۰۰۰ چک‌پوینت)، شکنندگی قوانین مقیاس‌پذیری نسبت به انتخاب‌های ابرپارامتری (مانند نرخ یادگیری و شکل مدل) را برجسته می‌کنند. آن‌ها روش Convex Hull را برای برازش قوانین پیشنهاد می‌دهند که نسبت به روش‌های پیشین بسیار مقاوم‌تر است.

۳.۵ تاثیر معماری و شکل مدل (Model Shape & Architecture)

یکی از مهم‌ترین نقایص قوانین گذشته، نادیده گرفتن تاثیر شکل مدل (نسبت عمق به عرض) و هزینه‌های استنتاج است.

- عرض در برابر عمق:** بیان و همکاران [۴] نشان می‌دهند که معماری مدل مستقیماً بر تاخیر استنتاج (Inference Latency) تاثیر می‌گذارد. مدل‌های عریض‌تر و کم‌عمق‌تر (Wider and Shallower) با بودجه پارامتری یکسان، توان عملیاتی (Throughput) بسیار بالاتری در استنتاج دارند. در همین راستا، لیو و همکاران [۵] پدیده Inverse Depth Scaling را معرفی می‌کنند؛ جایی که خطا با نسبت معکوس عمق ($1/\ell$) کاهش می‌یابد. آن‌ها دلیل این امر را میانگین‌گیری گروهی (Ensemble Averaging) لایه‌ها می‌دانند، به این معنا که لایه‌های متعدد در LLM‌ها کارهای مشابهی انجام می‌دهند و صرفاً با میانگین‌گیری، خطا را کاهش می‌دهند که نشان‌دهنده استفاده ناکارآمد از عمق است.

- تعامل عصبی (Neural Interaction):** سان و همکاران [۶] با استفاده از مفهوم Average Gradi-ent Outer Product (AGOP)، قانون «تعامل عصبی» را مطرح می‌کنند. آن‌ها نشان می‌دهند که تعمیم‌پذیری خوب نیازمند برهم‌نهی خوش‌خیم (Benign Superposition) است؛ جایی که مدل با انرژی تعاملی پایین، سهم بالایی از حساسیت تعاملی را به دست می‌آورد. نسبت عمق به عرض ($R_{D/W}$) ابزاری برای قرار دادن مدل در این بازه بهینه است.

- **قوانین مقیاس‌پذیری طیفی (Spectral Scaling Laws):** جها و ریگن [۷] نشان می‌دهند که افزایش عرض شبکه‌های پیش‌خور (FFN) عمدتاً ظرفیت‌های کم‌انرژی (دم طیف) را گسترش می‌دهد، در حالی که زیرفضاهای غالب به سرعت اشباع می‌شوند. این قانون مقیاس‌پذیری طیفی نامتقارن نشان می‌دهد که انتخاب عرض FFN یک مبادله بین ظرفیت دم و ظرفیت حالت غالب است.
- **معماری‌های جایگزین (Mamba و xLSTM):** یک و همکاران [۸] قوانین مقیاس‌پذیری معماری xLSTM (با پیچیدگی زمانی خطی) را با ترانسفورمرها مقایسه می‌کنند. نتایج نشان می‌دهد که xLSTM در مبادله محاسبات-خطا (Compute-Loss Trade-off) بر ترانسفورمرها برتری پارتو (Pareto-dominate) دارد. همچنین، در مقاله‌ای دیگر [۹] با رویکرد تفسیرپذیری مکانیسمی، نشان داده شده است که معماری Mamba بازیابی اطلاعات (Associative Recall) را از طریق یادگیری ضمنی توابع هش خطی انجام می‌دهد و کران‌های بالایی برای اندازه واژگان و ابعاد حالت بر اساس لم Johnson-Lindenstrauss ارائه می‌دهد.

۴.۵ قوانین مقیاس‌پذیری برای مدل‌های ترکیبی از خبرگان (MoE)

مدل‌های MoE به دلیل جداسازی تعداد کل پارامترها از هزینه محاسباتی (FLOPs)، نیازمند قوانین مقیاس‌پذیری مختص به خود هستند.

- **اهرم کارایی (Efficiency Leverage):** تیان و همکاران [۱۰] معیار EL را برای سنجش برتری محاسباتی MoE نسبت به مدل‌های متراکم (Dense) معرفی می‌کنند. آن‌ها نشان می‌دهند که نسبت فعال‌سازی (Activation Ratio) محرک اصلی کارایی است و دانه‌بندی خبرگان (Expert Granularity) به عنوان یک تعدیل‌کننده غیرخطی عمل می‌کند.
- **مبادله پارامتر و FLOPs:** آبنار و همکاران [۱۱] نشان می‌دهند که برای یک بودجه محاسباتی ثابت، افزایش سطح پراکندگی (Sparsity) – یعنی داشتن پارامترهای کل بیشتر اما پارامترهای فعال کمتر – منجر به کاهش خطای آموزش می‌شود.
- **کارایی حافظه:** برخلاف تصور رایج، لودزیجوسکی و همکاران [۱۲] ثابت می‌کنند که مدل‌های MoE می‌توانند از نظر حافظه نیز کارآمدتر از مدل‌های متراکم باشند، به شرطی که روی توکن‌های بیشتری آموزش ببینند.
- **بازیافت مدل‌ها (Upcycling):** لیو و همکاران [۱۳] به بررسی تبدیل مدل‌های متراکم از پیش‌آموزش‌دیده به MoE می‌پردازند. آن‌ها یک قانون مقیاس‌پذیری مشترک کشف کردند که نشان می‌دهد Upcycling تنها زمانی کارآمدتر از آموزش از صفر (From-scratch) است که هزینه اولیه (Sunk Cost) - توکن‌های آموزش مدل متراکم و اندازه مدل نسبتاً کوچک باشند.

۵.۵ نقش داده‌ها: کیفیت، ترکیب و چگالی

داده‌ها سوخت اصلی قوانین مقیاس‌پذیری هستند و کیفیت آن‌ها به اندازه کمیتشان اهمیت دارد.

- **کیفیت داده‌ها:** سوبرامانیام و همکاران [۱۴] یک پارامتر بدون بعد کیفیت به نام $Q \in (0, 1]$ را معرفی کرده و قانون Chinchilla را برای در نظر گرفتن کیفیت داده‌ها بسط می‌دهند. آن‌ها نشان می‌دهند که داده‌های با کیفیت بالا می‌توانند نیاز به اندازه مدل و محاسبات را به شدت کاهش دهند و اندازه موثر نمونه به صورت $D_{eff} = D \cdot Q^\gamma$ مقیاس می‌یابد.
- **ترکیب بهینه داده‌ها (Data Mixtures):** انتخاب نسبت ترکیب دامنه‌های مختلف داده معمولاً با آزمون و خطا انجام می‌شود. شوکور و همکاران [۱۵] روشی سیستماتیک ارائه می‌دهند که با استفاده از برازش قوانین مقیاس‌پذیری روی اجراهای مقیاس کوچک، می‌توان وزن‌های بهینه دامنه را برای آموزش مدل‌های بسیار بزرگ پیش‌بینی کرد.

- **ساختار سلسله‌مراتبی داده‌ها:** کاگنتا و همکاران [۱۶] با استفاده از مدل سلسله‌مراتب تصادفی (RHM)، نشان می‌دهند که شبکه‌های عصبی پیچیدگی‌های داده را لایه به لایه یاد می‌گیرند. آن‌ها ثابت می‌کنند که شبکه‌های پیچشی (CNNs) به دلیل اشتراک وزن و اتصال محلی، در یادگیری داده‌های سلسله‌مراتبی سریع‌تر از ترانسفورمرها مقیاس می‌یابند.

۶.۵ فراتر از خطای مطلق: معیارهای نوین ارزیابی

ارزیابی مدل‌ها صرفاً بر اساس خطای آنتروپی متقاطع (Cross-Entropy) تصویر کاملی از توانایی‌های مدل ارائه نمی‌دهد.

- **قوانین مقیاس‌پذیری نسبی (Relative Scaling Laws):** هلد و همکاران [۱۷] استدلال می‌کنند که ارزیابی‌های تجمیعی، تفاوت عملکرد در زیرگروه‌ها را پنهان می‌کند. آن‌ها قوانین نسبی را معرفی می‌کنند تا نشان دهند چگونه شکاف عملکرد بین توزیع‌ها با افزایش مقیاس تغییر می‌کند. نتایج نشان می‌دهد که مقیاس‌پذیری یک تساوی‌بخش جهانی نیست؛ در حالی که دامنه‌های علمی در MMLU به همگرایی می‌رسند، خطرات هوش مصنوعی (مانند توانایی فریکاری) با افزایش مقیاس واگرا شده و افزایش می‌یابند.

- **احتمال مبتنی بر رتبه (Relative-Based Probability):** یو و همکاران [۱۸] معیار RBP را معرفی می‌کنند که احتمال قرار گرفتن توکن صحیح در میان k پیش‌بینی برتر را می‌سنجد. آن‌ها نشان می‌دهند که $-\log(RBP_k)$ نیز از یک قانون توانی پیروی می‌کند. این دیدگاه پدیده ظهور توانایی‌ها (Emergence) را نه به عنوان یک جهش ناگهانی، بلکه به عنوان یک اثر ماکروسکوپی قابل پیش‌بینی از مقیاس‌پذیری میکروسکوپی هموار توضیح می‌دهد.

- **قانون چگال‌سازی (Densing Law):** در نهایت، شیائو و همکاران [۱۹] برای ارزیابی روند پیشرفت کارایی LLM‌ها در طول زمان، مفهوم چگالی قابلیت (Capability Density) را معرفی می‌کنند. مشاهدات تجربی آن‌ها نشان می‌دهد که حداکثر چگالی قابلیت مدل‌های متن‌باز تقریباً هر ۵.۳ ماه دو برابر می‌شود که نشان‌دهنده کاهش نمایی هزینه‌های استنتاج و نیازهای پارامتری برای رسیدن به یک سطح عملکرد ثابت است.

۷.۵ نتیجه‌گیری

بررسی جامع این مقالات نشان‌دهنده یک تغییر پارادایم در درک ما از قوانین مقیاس‌پذیری است. ما از دوران «بزرگتر بودن همیشه بهتر است» (صرفاً با افزایش پارامتر و داده) عبور کرده‌ایم. قوانین مقیاس‌پذیری نوین اکنون چندوجهی شده‌اند و باید هزینه‌های استنتاج، شکل معماری (عمق/عرض)، کیفیت و چگالی داده‌ها، ساختارهای پراکنده (MoE) و معیارهای ارزیابی نسبی را در بر بگیرند. این بینش‌های جدید به محققان و مهندسان اجازه می‌دهد تا مدل‌های زبانی آینده را نه تنها قدرتمندتر، بلکه از نظر محاسباتی، حافظه و استنتاج به مراتب کارآمدتر و هدفمندتر طراحی کنند.

۶ ارزیابی (Evaluation)

• sda

• sda

• sda

• sda

• sda

sda •

sda •

sda •

sda •

sda •

sda •

sda •

sda •

۷ یادگیری تقویتی (Reinforcement Learning)

sda •

۱.۷ الگوریتم بهینه‌سازی تقریبی خط‌مشی (Proximal Policy Optimization - PPO)

الگوریتم PPO که توسط جان شولمن (John Schulman) و همکارانش در سال ۲۰۱۷ در OpenAI معرفی شد [۲۰]، یکی از برجسته‌ترین، پایدارترین و پرکاربردترین الگوریتم‌های حوزه یادگیری تقویتی عمیق (Deep Reinforcement Learning) به شمار می‌رود. این الگوریتم با حل چالش‌های بنیادین بهینه‌سازی در روش‌های پیشین، تعادلی بهینه میان سادگی پیاده‌سازی، کارایی محاسباتی، بهره‌وری نمونه (Sample Efficiency) و پایداری همگرایی برقرار ساخته است.

تاریخچه، انگیزه و ضرورت پیدایش الگوریتم

پیش از ابداع PPO، روش‌های یادگیری تقویتی عمیق به سه دسته عمده با محدودیت‌های ساختاری تقسیم می‌شدند:

– **روش‌های مبتنی بر ارزش (Value-Based Methods):** شاخص‌ترین الگوریتم این دسته، DQN [۲۱] است. این روش‌ها گرچه در فضاهای عمل گسسته و محیط بازی‌های آتاری [۲۲] موفق ظاهر شدند، اما امکان تعمیم کارآمد به فضاهای عمل پیوسته (Continuous Action Spaces) با ابعاد بالا در رباتیک [۲۳، ۲۴] را نداشتند، چرا که یافتن $\arg \max_a Q(s, a)$ در هر گام نیازمند بهینه‌سازی غیرخطی زمان‌بر است. همچنین این روش‌ها از ناپایداری‌های ناشی از تقریب تابع و یادگیری خارج از خط‌مشی رنج می‌برند.

– **روش‌های گرادیان خط‌مشی استاندارد (Vanilla Policy Gradient):** روش‌هایی نظیر REINFORCE [۲۵] و A2C/A3C [۲۶] مستقیماً پارامترهای خط‌مشی را بهینه‌سازی می‌کنند. با این حال، به دلیل وابستگی گرادیان به توزیع داده‌های جمع‌آوری‌شده، مجاز به اجرای تنها یک گام گرادیان به ازای هر نمونه داده بودند. انجام چندین گام بهینه‌سازی (Multiple Epochs) روی داده‌های یکسان، منجر به جابجایی شدید خط‌مشی جدید نسبت به خط‌مشی قدیم و در نتیجه سقوط فاجعه‌بار کارایی (Catastrophic Policy Collapse) می‌شد؛ امری که باعث ناکارآمدی شدید در تعداد نمونه‌ها بود. (Sample Inefficiency)

– روش‌های بهینه‌سازی در ناحیه اطمینان (Trust Region Methods): کاکاده و لنگفورد [۲۷] و سپس شولمن و همکاران با معرفی الگوریتم TRPO [۲۸] نشان دادند که با مقید ساختن تغییرات خط‌مشی از طریق واگرایی کولیک-لایبلر (KL-Divergence)، می‌توان بهبود یکنواخت کارایی (Monotonic Improvement) را تضمین کرد. با این وجود، TRPO به محاسبات مرتبه دوم ماتریس اطلاعات فیشر (Fisher Information Matrix)، ماتریس هسین و حل با الگوریتم گرادیان مزدوج (Conjugate Gradient) نیازمند بود. این امر نه تنها پیچیدگی محاسباتی بالایی ایجاد می‌کرد، بلکه با معماری‌های دارای لایه‌های مشترک میان خط‌مشی و ارزش و تکنیک‌های نویزدار مانند Dropout ناسازگار بود.

هدف بنیادین PPO، دستیابی به ثبات، قابلیت اطمینان و نرخ همگرایی بالای TRPO، صرفاً با تکیه بر بهینه‌سازهای مشتق اول (First-Order Optimizers) نظیر بهینه‌ساز Adam [۲۹] و با سادگی پیاده‌سازی بالا است.

مبانی نظری و اشتقاق‌های کامل ریاضی

یک فرآیند تصمیم‌گیری مارکوف (MDP) با چندتایی متناهی یا نامتناهی $\mathcal{M} = (\mathcal{S}, \mathcal{A}, \mathcal{P}, r, \gamma, \rho_0)$ مدل‌سازی می‌شود که در آن $\mathcal{S}$ فضای حالات، $\mathcal{A}$ فضای اعمال، $\mathcal{P}(s'|s, a)$ تابع احتمال انتقال، $r(s, a)$ تابع پاداش، $\gamma \in [0, 1]$ ضریب تخفیف پاداش و $\rho_0(s_0)$ توزیع حالت اولیه است. توزیع یک مسیر (Trajectory) $\tau = (s_0, a_0, s_1, a_1, \dots, s_T)$ تحت خط‌مشی تصادفی پارامتریزه شده $\pi_\theta(a|s)$ برابر است با:

$$P(\tau; \theta) = \rho_0(s_0) \prod_{t=0}^{T-1} \pi_\theta(a_t|s_t) \mathcal{P}(s_{t+1}|s_t, a_t) \quad (۱)$$

هدف بهینه‌سازی، بیشینه‌سازی امید ریاضی بازده کل است:

$$J(\theta) = \mathbb{E}_{\tau \sim P(\cdot; \theta)}[R(\tau)] = \int_{\tau} P(\tau; \theta) R(\tau) d\tau \quad (۲)$$

که در آن $R(\tau) = \sum_{t=0}^T \gamma^t r(s_t, a_t)$ است. با اعمال عملگر گرادیان و استفاده از قاعده مشتق لگاریتمی $(\nabla_\theta P = P \nabla_\theta \log P)$:

$$\begin{aligned} \nabla_\theta J(\theta) &= \nabla_\theta \int P(\tau; \theta) R(\tau) d\tau = \int \nabla_\theta P(\tau; \theta) R(\tau) d\tau \\ &= \int P(\tau; \theta) \nabla_\theta \log P(\tau; \theta) R(\tau) d\tau = \mathbb{E}_{\tau \sim \pi_\theta} [\nabla_\theta \log P(\tau; \theta) R(\tau)] \end{aligned} \quad (۳)$$

از آنجا که جملات انتقال وضعیت محیط $\mathcal{P}$ به پارامتر θ وابسته نیستند، داریم $\nabla_\theta \log P(\tau; \theta) = \sum_{t=0}^T \nabla_\theta \log \pi_\theta(a_t|s_t)$. با بهره‌گیری از اصل علیت و کسر خط مبنای مستقل از عمل $b(s_t) = V(s_t)$ جهت کاهش واریانس، قضیه گرادیان خط‌مشی حاصل می‌شود:

$$\hat{g} = \hat{\mathbb{E}}_t [\nabla_\theta \log \pi_\theta(a_t|s_t) \hat{A}_t] \quad (۴)$$

که در آن $\hat{A}_t = Q(s_t, a_t) - V(s_t)$ برآوردگر تابع مزیت (Advantage Function) است.

با استفاده از مفهوم نمونه‌برداری ترجیحی (Importance Sampling)، هدف خط‌مشی برای داده‌های جمع‌آوری‌شده توسط $\pi_{\theta_{\text{old}}}$ به صورت تابع هدف جایگزین تکرار خط‌مشی محافظه‌کارانه (CPI) [۲۷] تعریف می‌شود:

$$L^{\text{CPI}}(\theta) = \hat{\mathbb{E}}_t \left[\frac{\pi_\theta(a_t|s_t)}{\pi_{\theta_{\text{old}}}(a_t|s_t)} \hat{A}_t \right] = \hat{\mathbb{E}}_t [r_t(\theta) \hat{A}_t] \quad (۵)$$

که در آن نسبت احتمالات $r_t(\theta) = \frac{\pi_\theta(a_t|s_t)}{\pi_{\theta_{\text{old}}}(a_t|s_t)}$ بوده و $r_t(\theta_{\text{old}}) = 1$ است.

توابع هدف در الگوریتم PPO

الگوریتم PPO دو فرمول‌بندی برای محدود ساختن تغییرات گام خط‌مشی ارائه می‌دهد:

۱. تابع هدف با برش جایگزین (Clipped Surrogate Objective): رویکرد اصلی و پیشنهادی مقاله، استفاده از تابع هدف زیر است:

$$L^{\text{CLIP}}(\theta) = \mathbb{E}_t \left[\min \left(r_t(\theta) \hat{A}_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_t \right) \right] \quad (6)$$

که در آن ϵ یک ابرپارامتر (معمولاً 0.2) است. این تابع هدف یک کران پایین بدبینانه (Pessimistic Lower Bound) را تشکیل می‌دهد:

- **در شرایط مثبت** ($\hat{A}_t > 0$): اگر عمل انجام‌شده بهتر از حد انتظار باشد، افزایش احتمال آن مفید است؛ اما به محض اینکه نسبت احتمال از $1 + \epsilon$ فراتر رود، گرادیان صفر شده و از تغییرات مفرط جلوگیری می‌کند.

- **در شرایط منفی** ($\hat{A}_t < 0$): اگر عمل بدتر از حد انتظار باشد، احتمال آن باید کاهش یابد؛ اگر نسبت احتمال از $1 - \epsilon$ کمتر شود، مقدار بریده شده و گرادیان صفر می‌شود. اما اگر خط‌مشی اشتباهاً احتمال این عمل بد را افزایش دهد ($r_t \gg 1$)، مقدار بدون برش انتخاب شده و جریمه کامل به خط‌مشی اعمال می‌شود.

۲. تابع هدف با ضریب جریمه تطبیقی (Adaptive KL Penalty): به عنوان رویکرد جایگزین، جریمه واگرایی KL مستقیماً در تابع هدف لحاظ شده و ضریب β به صورت دینامیک به‌روزرسانی می‌شود:

$$L^{\text{KL PEN}}(\theta) = \mathbb{E}_t \left[r_t(\theta) \hat{A}_t - \beta D_{\text{KL}}(\pi_{\theta_{\text{old}}}(\cdot|s_t) \parallel \pi_{\theta}(\cdot|s_t)) \right] \quad (7)$$

در هر تکرار، پس از محاسبه $d = \mathbb{E}_t[D_{\text{KL}}(\pi_{\theta_{\text{old}}} \parallel \pi_{\theta})]$ ، ضریب جریمه به این صورت تطبیق می‌یابد:

$$\beta \leftarrow \begin{cases} \beta/2 & \text{if } d < d_{\text{targ}}/1.5 \\ \beta \times 2 & \text{if } d > d_{\text{targ}} \times 1.5 \end{cases} \quad (8)$$

برآوردگر مزیت تعمیم‌یافته (GAE) و تابع هزینه یکپارچه

برای کاهش واریانس، از برآوردگر مزیت تعمیم‌یافته (GAE) منقطع [۳۰] استفاده می‌شود:

$$\hat{A}_t = \sum_{l=0}^{T-t-1} (\gamma \lambda)^l \delta_{t+l}^V \quad \text{where} \quad \delta_t^V = r_t + \gamma V(s_{t+1}) - V(s_t) \quad (9)$$

برای شبکه‌های دارای پارامترهای مشترک میان خط‌مشی و تابع ارزش، تابع هزینه سراسری بهینه‌سازی زیر پیشنهاد می‌گردد:

$$L_t^{\text{CLIP+VF+S}}(\theta) = \mathbb{E}_t \left[L_t^{\text{CLIP}}(\theta) - c_1 \left(V_{\theta}(s_t) - V_t^{\text{targ}} \right)^2 + c_2 S[\pi_{\theta}](s_t) \right] \quad (10)$$

که در آن $S[\pi_{\theta}]$ آنتروپی شانون برای تشویق به اکتشاف (Exploration) و c_1, c_2 ضرایب وزنی هستند.

تحلیل‌های تئوری اطلاعات و آمار

بر اساس بسط تیلور مرتبه دوم واگرایی KL حول نقطه θ_{old} داریم:

$$D_{\text{KL}}(\pi_{\theta_{\text{old}}} \parallel \pi_{\theta}) \approx \frac{1}{2}(\theta - \theta_{\text{old}})^T F(\theta - \theta_{\text{old}}) \quad (11)$$


که در آن $F = \mathbb{E}[\nabla_{\theta} \log \pi_{\theta} \nabla_{\theta} \log \pi_{\theta}^T]$ ماتریس اطلاعات فیشر است. تابع برش در PPO تضمین می‌کند که فاصله روی منیفلد ریمانی توزیع‌ها بدون نیاز به تشکیل و معکوس کردن صریح ماتریس F در محدوده‌ای امن محبوس بماند. همچنین با محدود کردن $r_t(\theta) \in [1 - \epsilon, 1 + \epsilon]$ واریانس بازوزن‌دهی نمونه‌برداری ترجیحی ($\text{Var}_Q[P/Q \cdot f]$) کنترل شده و از انفجار واریانس در بهینه‌سازی چند دوره‌ای جلوگیری می‌شود.

دیگرام معماری و جریان داده‌های الگوریتم

شکل ۱، ساختار تعامل با محیط، محاسبه مزیت، تشکیل توابع هدف و چرخه به‌روزرسانی چند دوره‌ای در الگوریتم PPO را نشان می‌دهد.

شبه‌کد الگوریتم PPO

شبه‌کد استاندارد ساختار Actor-Critic الگوریتم PPO در الگوریتم ۱ آورده شده است:



شکل ۱: دیاگرام جامع جریان داده‌ها، محاسبه مزیت و بهینه‌سازی چند دوره‌ای در الگوریتم PPO.

Algorithm 1 Proximal Policy Optimization (PPO), Actor-Critic Style

```

1: Input: Initial policy parameters  $\theta_0$ , initial value function parameters  $\phi_0$ , clipping threshold  $\epsilon$ ,
   GAE parameters  $\gamma, \lambda$ , epoch count  $K$ , minibatch size  $M$ , coefficients  $c_1, c_2$ .
2: for iteration = 1, 2, ... do
3:   for actor = 1, ...,  $N$  do
4:     Run policy  $\pi_{\theta_{\text{old}}}$  in environment for  $T$  timesteps.
5:     Compute predictions  $V_\phi(s_t)$  and log-probabilities  $\log \pi_{\theta_{\text{old}}}(a_t|s_t)$ .
6:     Compute TD residuals:  $\delta_t^V = r_t + \gamma V_\phi(s_{t+1}) - V_\phi(s_t)$ .
7:     Compute GAE estimates:  $\hat{A}_t = \sum_{l=0}^{T-t-1} (\gamma\lambda)^l \delta_{t+l}^V$ .
8:     Compute state-value targets:  $V_t^{\text{targ}} = \hat{A}_t + V_\phi(s_t)$ .
9:   end for
10:  Collect all  $NT$  transitions:  $\mathcal{D} = \{(s_t, a_t, r_t, \log \pi_{\theta_{\text{old}}}(a_t|s_t), \hat{A}_t, V_t^{\text{targ}})\}$ .
11:  Normalize advantage values:  $\hat{A}_t \leftarrow \frac{\hat{A}_t - \mu(\hat{A})}{\sigma(\hat{A}) + 10^{-8}}$ .
12:  for epoch = 1, ...,  $K$  do
13:    Shuffle dataset  $\mathcal{D}$  and partition into minibatches of size  $M$ .
14:    for each minibatch  $\mathcal{B} \subset \mathcal{D}$  do
15:      Compute probability ratio:  $r_t(\theta) = \exp(\log \pi_\theta(a_t|s_t) - \log \pi_{\theta_{\text{old}}}(a_t|s_t))$ .
16:      Compute policy surrogate loss:
17:       $L^{\text{CLIP}}(\theta) = \frac{1}{|\mathcal{B}|} \sum_{t \in \mathcal{B}} \min(r_t(\theta)\hat{A}_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon)\hat{A}_t)$ .
18:      Compute value function squared error loss:
19:       $L^{\text{VF}}(\phi) = \frac{1}{|\mathcal{B}|} \sum_{t \in \mathcal{B}} (V_\phi(s_t) - V_t^{\text{targ}})^2$ .
20:      Compute entropy bonus:  $S[\pi_\theta] = \frac{1}{|\mathcal{B}|} \sum_{t \in \mathcal{B}} \mathbb{H}(\pi_\theta(\cdot|s_t))$ .
21:      Maximize total objective using Adam:
22:       $\theta, \phi \leftarrow \text{Adam}(\nabla_{\theta, \phi} [L^{\text{CLIP}}(\theta) - c_1 L^{\text{VF}}(\phi) + c_2 S[\pi_\theta]])$ .
23:    end for
24:  end for
25:   $\theta_{\text{old}} \leftarrow \theta$ 
26: end for

```

نتایج تجربی و ارزیابی بنچمارک‌ها

کارایی PPO در مقایسه با انواع روش‌های بهینه‌سازی در جدول ۱ و روی بازی‌های آتاری در جدول ۲ خلاصه شده است:

ابزارهای استاندارد گزارش‌شده در مقاله

جداول ۳ و ۴ مقادیر دقیق ابزارهای بهینه‌شده برای محیط‌های مختلف را نمایش می‌دهند:

جمع‌بندی

الگوریتم PPO به واسطه تابع برش بدبینانه L^{CLIP} ، بدون نیاز به محاسبات سنگین ماتریس فیشر و با استفاده مستقیم از گرادینت مرتبه اول Adam، رفتار ناحیه اطمینان را شبیه‌سازی کرده و امروزه به عنوان پایه‌ای‌ترین و مطمئن‌ترین الگوریتم یادگیری تقویتی در زمینه‌های مختلف از کنترل حرکت ربات‌های سه‌بعدی [۳۱] تا هم‌ترازسازی مدل‌های زبانی بزرگ از طریق بازخورد انسانی (RLHF) شناخته می‌شود.

جدول ۱: مقایسه عملکرد انواع توابع هدف جایگزین در ۷ محیط پیوسته MuJoCo (برگرفته از مقاله مرجع [۲۰]).

فرمول بندی الگوریتم / تابع هدف	میانگین امتیاز نرمال شده
بدون برش و بدون جریمه (No clipping or penalty)	۳۹.۰-
برش با $\epsilon = 0.1$ (Clipping)	۷۶.۰
برش با $\epsilon = 0.2$ (Clipping)	۸۲.۰
برش با $\epsilon = 0.3$ (Clipping)	۷۰.۰
جریمه تطبیقی با $d_{\text{targ}} = 0.003$ (Adaptive KL)	۶۸.۰
جریمه تطبیقی با $d_{\text{targ}} = 0.01$ (Adaptive KL)	۷۴.۰
جریمه تطبیقی با $d_{\text{targ}} = 0.03$ (Adaptive KL)	۷۱.۰
جریمه ثابت با $\beta = 0.3$ (Fixed KL)	۶۲.۰
جریمه ثابت با $\beta = 1.0$ (Fixed KL)	۷۱.۰
جریمه ثابت با $\beta = 3.0$ (Fixed KL)	۷۲.۰
جریمه ثابت با $\beta = 10.0$ (Fixed KL)	۶۹.۰

جدول ۲: تعداد بازی های برده شده توسط هر الگوریتم در بنچمارک ۴۹ تایی آتاری (ALE) [۲۰].

معیار ارزیابی	A2C	ACER	PPO	تساوی
(۱) میانگین پاداش در کل طول آموزش	۱	۱۸	۳۰	۰
(۲) میانگین پاداش در ۱۰۰ اپیزود پایانی	۱	۲۸	۱۹	۱

جدول ۳: ابرپارامترهای PPO در بنچمارک رباتیک پیوسته MuJoCo (۱ میلیون گام).

مقدار	ابروپارامتر
۲۰۴۸	افق زمانی داده برداری (T)
3×10^{-4}	نرخ یادگیری بهینه ساز Adam
۱۰	تعداد دور بهینه سازی در هر آپدیت (K)
۶۴	اندازه دسته کوچک (M)
۹۹.۰	ضریب تخفیف پاداش (γ)
۹۵.۰	پارامتر برآوردگر مزیت (λ)

جدول ۴: ابرپارامترهای PPO در بنچمارک بازی های آتاری (Atari).

مقدار	ابروپارامتر
۱۲۸	افق زمانی داده برداری (T)
$2.5 \times 10^{-4} \times \alpha$	نرخ یادگیری Adam
۸	تعداد عامل های موازی (N)
۳	تعداد دورها (K)
$32 \times 8 = 256$	اندازه دسته کوچک (M)
۹۹.۰	ضریب تخفیف پاداش (γ)
۹۵.۰	پارامتر λ در GAE
$0.1 \times \alpha$	آستانه برش (ϵ)
۰.۱	ضریب خطای تابع ارزش (c_1)
۰.۱۰	ضریب پاداش آنتروپی (c_2)

۲.۷ الگوریتم بهینه‌سازی نسبی خط‌مشی گروهی (Group Relative Policy Optimization - GRPO)

الگوریتم GRPO که توسط تیم DeepSeek-AI در سال ۲۰۲۴ معرفی شد [۳۲]، یکی از پیشرفته‌ترین و کارآمدترین الگوریتم‌های یادگیری تقویتی در حوزه هم‌ترازسازی مدل‌های زبانی بزرگ (LLMs) برای مسائل استدلالی پیچیده و ریاضیات به شمار می‌رود. این الگوریتم با بازتعریف شیوه محاسبه مزیت و حذف کامل مدل منتقد (Critic Model)، بار حافظه و محاسبات الگوریتم‌های سنتی نظیر PPO را به طور چشمگیری کاهش داده و همگرایی پایدارتری را به نمایش می‌گذارد.

تاریخچه، انگیزه و ضرورت پیدایش الگوریتم

الگوریتم بهینه‌سازی تقریبی خط‌مشی (PPO) [۲۰] به عنوان استاندارد اصلی در مرحله یادگیری تقویتی از بازخورد انسانی (RLHF) [۳۳] شناخته می‌شود. با این حال، استفاده از ساختار کنشگر-منتقد (Actor-Critic) در مدل‌های زبانی با موانع اساسی زیر همراه است:

- **بار سنگین حافظه و محاسبات (Memory and Compute Footprint):** در PPO استاندارد، مدل منتقد (V_ψ) از نظر ابعاد پارامتری هم‌اندازه مدل خط‌مشی (π_θ) است. بارگذاری، محاسبه گرادیان و نگهداری متغیرهای بهینه‌ساز برای هر دو مدل، حجم عظیمی از حافظه پردازشی (VRAM) را اشغال می‌کند.
- **پاداش‌های تنک و عدم انطباق با تقریب ارزش توکنی (Sparse Reward Mismatch):** در استدلال‌های ریاضی، پاداش‌ها معمولاً در انتهای توالی (Outcome) یا در انتهای هر گام استدلال (Process) صادر می‌شوند. آموزش یک تابع ارزش برای پیش‌بینی ارزش تک‌تک توکن‌ها در طول یک متن طولانی، دارای واریانس بسیار بالا و خطای تقریب شدید است.
- **طبیعت مقایسه‌ای مدل‌های پاداش (Comparative Nature of Reward Models):** مدل‌های پاداش ذاتاً بر اساس مقایسه نسبی بین گزینه‌ها آموزش می‌بینند. تلاش مدل منتقد برای یادگیری ارزش مطلق به صورت نقطه‌ای، همخوانی کاملی با ماهیت نسبی سیگنال‌های پاداش ندارد.

الگوریتم GRPO با حذف کامل مدل ارزش و جایگزینی آن با خط مبنای آماری حاصل از گروهی از پاسخ‌های تولیدشده برای یک پرسش یکسان، این چالش‌ها را به طور بنیادین برطرف می‌سازد.

مبانی نظری و اشتقاق‌های کامل ریاضی

فرض کنید q یک پرسش از توزیع داده‌های آموزشی باشد. الگوریتم GRPO به ازای هر پرسش q ، گروهی متشکل از G خروجی $\{o_1, o_2, \dots, o_G\}$ را از خط‌مشی پیشین $\pi_{\theta_{old}}$ نمونه‌برداری می‌کند. ۱. **تابع هدف بهینه‌سازی GRPO:** تابع هدف سراسری این الگوریتم به صورت زیر فرمول‌بندی می‌شود:

$$\mathcal{J}_{GRPO}(\theta) = \mathbb{E}_{\substack{q \sim P(Q) \\ \{o_i\}_{i=1}^G \sim \pi_{\theta_{old}}(O|q)}} \left[\frac{1}{G} \sum_{i=1}^G \frac{1}{|o_i|} \sum_{t=1}^{|o_i|} \left(\min \left(\frac{\pi_\theta(o_{i,t}|q, o_{i,<t})}{\pi_{\theta_{old}}(o_{i,t}|q, o_{i,<t})} \hat{A}_{i,t}, \right. \right. \right. \\ \left. \left. \left. \text{clip} \left(\frac{\pi_\theta(o_{i,t}|q, o_{i,<t})}{\pi_{\theta_{old}}(o_{i,t}|q, o_{i,<t})}, 1 - \varepsilon, 1 + \varepsilon \right) \hat{A}_{i,t} \right) - \beta \mathbb{D}_{KL}(\pi_\theta \parallel \pi_{ref}) \right] \quad (12)$$

که در آن ε آستانه برش برای جلوگیری از به‌روزرسانی‌های مخرب، β ضریب جریمه واگرایی کولبک-لایبلر و $\hat{A}_{i,t}$ مزیت نرمال‌شده در سطح گروه است.

۲. اثبات نارویی و نامنفی بودن تخمین گر واگرایی KL: در این الگوریتم، به جای تزریق جریمه واگرایی به عنوان پاداش به ازای هر توکن، از تخمین گر نارویی شولمن [۳۴] به صورت مستقیم در تابع زیان استفاده می‌شود:

$$\mathbb{D}_{\text{KL}}(\pi_{\theta} \parallel \pi_{\text{ref}}) = \frac{\pi_{\text{ref}}(o_{i,t}|q, o_{i,<t})}{\pi_{\theta}(o_{i,t}|q, o_{i,<t})} - \log \frac{\pi_{\text{ref}}(o_{i,t}|q, o_{i,<t})}{\pi_{\theta}(o_{i,t}|q, o_{i,<t})} - 1 \quad (۱۳)$$

اثبات نامنفی بودن: فرض کنید $r = \frac{\pi_{\text{ref}}}{\pi_{\theta}} > 0$ باشد. تابع $f(r) = r - \log r - 1$ را در نظر می‌گیریم. مشتقات اول و دوم این تابع عبارتند از:

$$f'(r) = 1 - \frac{1}{r}, \quad f''(r) = \frac{1}{r^2} > 0 \quad (\forall r > 0) \quad (۱۴)$$

از آنجا که مشتق دوم همواره مثبت است، تابع اکیداً محدب بوده و نقطه بحرانی آن در $f'(r) = 0 \implies r = 1$ یک کمینه مطلق است:

$$f(1) = 1 - \log(1) - 1 = 0 \implies f(r) \geq 0 \quad (\forall r > 0) \quad (۱۵)$$

اثبات نارویی: امید ریاضی این تخمین گر تحت توزیع کنونی خطمشی π_{θ} برابر است با:

$$\begin{aligned} \mathbb{E}_{x \sim \pi_{\theta}} \left[\frac{\pi_{\text{ref}}(x)}{\pi_{\theta}(x)} - \log \frac{\pi_{\text{ref}}(x)}{\pi_{\theta}(x)} - 1 \right] &= \sum_x \pi_{\theta}(x) \left(\frac{\pi_{\text{ref}}(x)}{\pi_{\theta}(x)} - \log \frac{\pi_{\text{ref}}(x)}{\pi_{\theta}(x)} - 1 \right) \\ &= \sum_x \pi_{\text{ref}}(x) - \sum_x \pi_{\theta}(x) \log \frac{\pi_{\text{ref}}(x)}{\pi_{\theta}(x)} - \sum_x \pi_{\theta}(x) \\ &= 1 + \sum_x \pi_{\theta}(x) \log \frac{\pi_{\theta}(x)}{\pi_{\text{ref}}(x)} - 1 = D_{\text{KL}}(\pi_{\theta} \parallel \pi_{\text{ref}}) \end{aligned} \quad (۱۶)$$

۳. اشتقاق گرادیان و ضریب گرادیان (Gradient Coefficient): با در نظر گرفتن شرایط خطمشی در گام نخست ($\pi_{\theta_{\text{old}}} \approx \pi_{\theta}$)، مشتق تابع هدف را نسبت به پارامترهای θ به دست می‌آوریم:

$$\nabla_{\theta} \mathcal{L}_{i,t}(\theta) = \nabla_{\theta} \left[\frac{\pi_{\theta}(o_{i,t})}{\pi_{\theta_{\text{old}}}(o_{i,t})} \hat{A}_{i,t} \right] - \beta \nabla_{\theta} \left[\frac{\pi_{\text{ref}}(o_{i,t})}{\pi_{\theta}(o_{i,t})} - \log \frac{\pi_{\text{ref}}(o_{i,t})}{\pi_{\theta}(o_{i,t})} - 1 \right] \quad (۱۷)$$

با استفاده از تساوی $\nabla_{\theta} \pi_{\theta} = \pi_{\theta} \nabla_{\theta} \log \pi_{\theta}$:

$$\nabla_{\theta} \left[\frac{\pi_{\theta}}{\pi_{\theta_{\text{old}}}} \hat{A}_{i,t} \right] = \hat{A}_{i,t} \nabla_{\theta} \log \pi_{\theta}(o_{i,t}) \quad (۱۸)$$

$$\nabla_{\theta} \left[\frac{\pi_{\text{ref}}}{\pi_{\theta}} - \log \pi_{\text{ref}} + \log \pi_{\theta} - 1 \right] = -\frac{\pi_{\text{ref}}}{\pi_{\theta}^2} \nabla_{\theta} \pi_{\theta} + \frac{1}{\pi_{\theta}} \nabla_{\theta} \pi_{\theta} = \left(1 - \frac{\pi_{\text{ref}}}{\pi_{\theta}} \right) \nabla_{\theta} \log \pi_{\theta}(o_{i,t}) \quad (۱۹)$$

با تجميع دو عبارت فوق، گرادیان کامل به صورت زیر حاصل می‌شود:

$$\nabla_{\theta} \mathcal{J}_{\text{GRPO}}(\theta) = \mathbb{E} \left[\frac{1}{G} \sum_{i=1}^G \frac{1}{|o_i|} \sum_{t=1}^{|o_i|} \left(\hat{A}_{i,t} + \beta \left(\frac{\pi_{\text{ref}}(o_{i,t})}{\pi_{\theta}(o_{i,t})} - 1 \right) \right) \nabla_{\theta} \log \pi_{\theta}(o_{i,t}|q, o_{i,<t}) \right] \quad (۲۰)$$

بنابراین ضریب گرادیان (Gradient Coefficient - GC) در این روش برابر است با:

$$GC_{\text{GRPO}}(q, o, t, \pi_{\theta_{\text{rm}}}) = \hat{A}_{i,t} + \beta \left(\frac{\pi_{\text{ref}}(o_{i,t}|q, o_{i,<t})}{\pi_{\theta}(o_{i,t}|q, o_{i,<t})} - 1 \right) \quad (۲۱)$$

رویکردهای نظارت و محاسبه مزیت در GRPO

الگوریتم GRPO امکان بهره‌گیری از دو نوع ناظر را برای تعیین پاداش فراهم می‌سازد:

۱. **نظارت بر خروجی (Outcome Supervision RL with GRPO):** مدل پاداش به ازای هر پاسخ کامل o_i یک امتیاز r_i تولید می‌کند. بردار پاداش گروهی $\mathbf{r} = \{r_1, r_2, \dots, r_G\}$ به شکل زیر نرمال‌سازی می‌شود:

$$\hat{A}_{i,t} = \tilde{r}_i = \frac{r_i - \text{mean}(\mathbf{r})}{\text{std}(\mathbf{r}) + 10^{-8}}, \quad \forall t \in \{1, \dots, |o_i|\} \quad (22)$$

۲. **نظارت بر فرآیند (Process Supervision RL with GRPO):** مدل پاداش فرایندی (PRM) [۳۵، ۳۶] به انتهای هر گام استدلال j پاداش $r_i^{\text{index}(j)}$ اختصاص می‌دهد. با نرمال‌سازی کل پاداش‌های مرحله‌ای درون گروه:

$$\tilde{r}_i^{\text{index}(j)} = \frac{r_i^{\text{index}(j)} - \text{mean}(\mathbf{R})}{\text{std}(\mathbf{R}) + 10^{-8}} \quad (23)$$

سپس مزیت هر توکن در موقعیت t از مجموع پاداش‌های گام‌های پسین محاسبه می‌شود:

$$\hat{A}_{i,t} = \sum_{\substack{j=1 \\ \text{index}(j) \geq t}}^{K_i} \tilde{r}_i^{\text{index}(j)} \quad (24)$$

چارچوب یکپارچه روش‌های هم‌ترازسازی

مقاله یک صورت‌بندی فراگیر ارائه می‌دهد که تمامی روش‌های تنظیم دقیق و یادگیری تقویتی را تحت معادله گرادیان زیر متحد می‌سازد:

$$\nabla_{\theta} \mathcal{J}_{\mathcal{A}}(\theta) = \mathbb{E}_{(q,o) \sim \mathcal{D}} \left[\frac{1}{|o|} \sum_{t=1}^{|o|} GC_{\mathcal{A}}(q, o, t, \pi_{\text{ref}}) \nabla_{\theta} \log \pi_{\theta}(o_t | q, o_{<t}) \right] \quad (25)$$

جدول ۵ مقایسه ساختاری این روش‌ها را نشان می‌دهد:

جدول ۵: تحلیل ساختار روش‌های هم‌ترازسازی در چارچوب یکپارچه گرادیان [۳۲].

روش (Method)	منبع داده ($\mathcal{D}$)	تابع پاداش (π_{ref})	ضریب گرادیان (GC)	نوع نمونه‌برداری
SFT	$q, o \sim P_{\text{sft}}(Q, O)$	انتخاب انسانی	1	آفلاین ایستا
[۳۷] RFT	$q \sim P_{\text{sft}}(Q), o \sim \pi_{\text{sft}}(O q)$	قاعده قطعی (Rule)	$\mathbb{I}(o \text{ correct is})$	آفلاین تصادفی
[۳۸] DPO	$q \sim P_{\text{sft}}(Q), o^+, o^- \sim \pi_{\text{sft}}(O q)$	ترجیح / قاعده	$\sigma \left(\beta \log \frac{\pi_{\theta}(o^-)}{\pi_{\text{ref}}(o^-)} - \beta \log \frac{\pi_{\theta}(o^+)}{\pi_{\text{ref}}(o^+)} \right)$	آفلاین زوجی
Online RFT	$q \sim P_{\text{sft}}(Q), o \sim \pi_{\theta}(O q)$	قاعده قطعی (Rule)	$\mathbb{I}(o \text{ correct is})$	آنلاین تصادفی
[۲۰] PPO	$q \sim P_{\text{sft}}(Q), o \sim \pi_{\theta}(O q)$	مدل پاداش	$A_t = \text{GAE}(\{r_{\geq t}\}, V_{\psi})$	آنلاین پیوسته
GRPO	$q \sim P_{\text{sft}}(Q), \{o_i\}_{i=1}^G \sim \pi_{\theta}(O q)$	مدل پاداش / فرآیند	$\hat{A}_{i,t} + \beta \left(\frac{\pi_{\text{ref}}(o_{i,t})}{\pi_{\theta}(o_{i,t})} - 1 \right)$	آنلاین گروهی

تحلیل‌های تئوری اطلاعات، آمار و چرایی موفقیت الگوریتم

– **کاهش واریانس بدون منتقد:** میانگین پاداش درون‌گروهی r_i $b(q) = \frac{1}{G} \sum_{i=1}^G r_i$ به عنوان خط مبنای نارایب عمل کرده و واریانس تخمین‌گر به میزان $\mathcal{O}(1/G)$ کاهش می‌یابد بدون آنکه نیازی به خطای تخمین مدل منتقد ($\epsilon_{\text{critic}} = V^*(s) - V_{\psi}(s)$) باشد.

– **تحلیل معیارهای Pass@K در برابر Maj@K:** ارزیابی‌های تجربی روی بنچمارک‌های GSM8K و MATH نشان می‌دهند که یادگیری تقویتی توان بالقوه خام (Pass@K) مدل را نسبت به مرحله SFT تغییر چشمگیری نمی‌دهد؛ بلکه توزیع احتمالاتی پاسخ‌ها را کالیبره کرده و با متمرکز ساختن چگالی احتمال حول پاسخ‌های صحیح، دقت رأی‌گیری اکثریت (Maj@K) و پاسخ برتر (Top-1) را به شدت ارتقا می‌بخشد.

دیگرام معماری و جریان داده‌های الگوریتم

شکل ۲ ساختار داده‌برداری گروهی، نرمال‌سازی آماری، محاسبه ضریب گرادیان و چرخه به‌روزرسانی بدون منتقد را در الگوریتم GRPO نمایش می‌دهد.

شبه‌کد الگوریتم GRPO

شبه‌کد کامل فرایند بهینه‌سازی سیاست نسبی گروهی تکرارشونده در الگوریتم ۲ تشریح شده است:

Algorithm 2 Iterative Group Relative Policy Optimization (GRPO)

```

1: Input: Initial policy  $\pi_{\theta_{\text{init}}}$ , reward model  $r_{\varphi}$ , prompt dataset  $\mathcal{D}$ , hyperparameters  $\varepsilon, \beta, \mu, G$ , iterations  $I$ , steps  $M$ .
2: Initialize policy  $\pi_{\theta} \leftarrow \pi_{\theta_{\text{init}}}$ 
3: for iteration = 1, ...,  $I$  do
4:   Set reference policy  $\pi_{\text{ref}} \leftarrow \pi_{\theta}$ 
5:   for step = 1, ...,  $M$  do
6:     Sample batch of prompts  $\mathcal{D}_b \sim \mathcal{D}$ 
7:     Update old policy  $\pi_{\theta_{\text{old}}} \leftarrow \pi_{\theta}$ 
8:     Sample  $G$  candidate outputs  $\{o_i\}_{i=1}^G \sim \pi_{\theta_{\text{old}}}(\cdot|q)$  for each prompt  $q \in \mathcal{D}_b$ 
9:     Compute rewards  $\{r_i\}_{i=1}^G$  using reward model  $r_{\varphi}$ 
10:    Compute group mean and standard deviation:
11:    
$$\mu_{\mathbf{r}} = \frac{1}{G} \sum_{i=1}^G r_i, \quad \sigma_{\mathbf{r}} = \sqrt{\frac{1}{G} \sum_{i=1}^G (r_i - \mu_{\mathbf{r}})^2 + 10^{-8}}$$

12:    Compute group relative advantages:  $\hat{A}_{i,t} = \frac{r_i - \mu_{\mathbf{r}}}{\sigma_{\mathbf{r}}}$ 
13:    for GRPO iteration = 1, ...,  $\mu$  do
14:      Compute ratio:  $\rho_{i,t} = \frac{\pi_{\theta}(o_{i,t}|q, o_{i,<t})}{\pi_{\theta_{\text{old}}}(o_{i,t}|q, o_{i,<t})}$ 
15:      Compute clipped advantage objective:
16:      
$$\mathcal{L}_{i,t}^{\text{CLIP}} = \min \left( \rho_{i,t} \hat{A}_{i,t}, \text{clip}(\rho_{i,t}, 1 - \varepsilon, 1 + \varepsilon) \hat{A}_{i,t} \right)$$


17:      Compute token-level Schulman KL penalty:
18:      
$$\mathbb{D}_{\text{KL},i,t} = \frac{\pi_{\text{ref}}(o_{i,t}|q, o_{i,<t})}{\pi_{\theta}(o_{i,t}|q, o_{i,<t})} - \log \frac{\pi_{\text{ref}}(o_{i,t}|q, o_{i,<t})}{\pi_{\theta}(o_{i,t}|q, o_{i,<t})} - 1$$

19:      Maximize GRPO loss with AdamW:
20:      
$$\theta \leftarrow \theta + \alpha \nabla_{\theta} \left[ \frac{1}{G|\mathcal{D}_b|} \sum_{q \in \mathcal{D}_b} \sum_{i=1}^G \frac{1}{|o_i|} \sum_{t=1}^{|o_i|} (\mathcal{L}_{i,t}^{\text{CLIP}} - \beta \mathbb{D}_{\text{KL},i,t}) \right]$$

21:    end for
22:    Update reward model  $r_{\varphi}$  through replay mechanism with 10% historical samples.
23:  end for
24: end for
25: Output: Optimized Policy  $\pi_{\theta}$ 
```

نتایج تجربی و ارزیابی بنچمارک‌ها

نتایج حاصل از اعمال الگوریتم GRPO بر روی مدل پایه DeepSeekMath-Instruct 7B در مقایسه با سایر مدل‌های باز و بسته در جدول ۶ ارائه شده است:



شکل ۲: دیاگرام جامع جریان داده‌ها، ارزیابی آماری گروهی و به‌روزرسانی بدون منتقد در الگوریتم GRPO.

جدول ۶: مقایسه عملکرد DeepSeekMath-RL (GRPO) با مدل‌های پیشرو در بنچمارک‌های استدلال ریاضی [۳۲].

مدل (Model)	تعداد پارامتر	GSM8K (CoT)	MATH (CoT)	MGSM-zh	CMATH
مدل‌های تجاری و بسته (Closed-Source Models)					
Gemini Ultra	-	۴۰.۹۴	۲۰.۵۳	-	-
GPT-4	-	۰.۹۲	۹.۵۲	-	۰.۸۶
Inflection-2	-	۴۰.۸۱	۸.۳۴	-	-
GLM-4	-	۶۰.۸۷	۹.۴۷	-	-
مدل‌های منبع باز (Open-Source Models)					
InternLM2-Math	۲۰B	۶۰.۸۲	۷۰.۳۷	-	-
Qwen	۷۲B	۹۰.۷۸	۲۰.۳۵	-	-
WizardMath-v1.1	۷B	۲۰.۸۳	۰.۳۳	-	-
DeepSeekMath-Instruct	۷B	۹۰.۸۲	۸.۴۶	۲۰.۷۳	۶۰.۸۴
DeepSeekMath-RL (GRPO)	۷B	۲۰.۸۸	۷۰.۵۱	۶۰.۷۹	۸۰.۸۸

ابریارمترهای استاندارد گزارش شده در مقاله

جدول ۷ پیکربندی ابریارمترهای بهینه پیاده‌سازی GRPO را نشان می‌دهد:

جدول ۷: ابریارمترهای آموزش یادگیری تقویتی با GRPO در مدل DeepSeekMath 7B.

مقدار	ابریارمتر (Hyperparameter)
1×10^{-6}	نرخ یادگیری مدل خط‌مشی (α)
2×10^{-5}	نرخ یادگیری مدل پاداش اولیه
۶۴	تعداد نمونه‌های خروجی در هر گروه (G)
۰.۴۰	ضریب جریمه واگرایی کولبک-لایبلر (β)
۲.۰	آستانه برش پروگزیمال (ϵ)
۱۰۲۴	اندازه دسته بهینه‌سازی (Batch Size)
۱۰۲۴	حداکثر طول توالی خروجی (Max Length)
۷.۰	دمای نمونه‌برداری اکتشافی (Sampling Temperature)

جمع‌بندی

الگوریتم GRPO با حذف کامل سربار محاسباتی و حافظه مدل منتقد و جایگزینی آن با نرمال‌سازی آماری در سطح گروه‌های هم‌ارز، مسیر نوینی را در یادگیری تقویتی مدل‌های زبانی گشوده است. این نوآوری به مدل DeepSeekMath 7B اجازه داد تا با صرفه‌جویی شدید در منابع سخت‌افزاری، به دقت فراتر از ۵۱٪ در بنچمارک معتبر MATH دست یافته و استانداردهای جدیدی در زمینه استدلال هوش مصنوعی پایه‌گذاری کند.

۳.۷ الگوریتم بهینه‌سازی توالی گروهی خط‌مشی (Group Sequence Policy Optimization - GSPO)

الگوریتم GSPO که در سال ۲۰۲۵ توسط تیم کوئن (Qwen Team) در شرکت علی‌بابا (Alibaba Inc.) معرفی شد [۳۹]، یک چارچوب نوین، فوق‌العاده پایدار و کارآمد در زمینه یادگیری تقویتی (Reinforce Learning) برای مدل‌های زبانی بزرگ (LLMs) به شمار می‌رود. این الگوریتم با بازنگری در

شیوه اعمال «نمونه‌برداری اهمیت» (Importance Sampling) و اصلاح خطاهای ساختاری الگوریتم‌های پیشین نظیر GRPO [۳۲]، کلیه فرآیندهای وزن‌دهی نسبت درستی‌نمایی، برش‌گرادیان (Clipping) و بهینه‌سازی را از سطح «توکن» (Token-level) به سطح «توالی کامل» (Sequence-level) منتقل کرده است. این رویکرد به عنوان ستون فقرات یادگیری تقویتی در آموزش مدل‌های استدلالی پیشرفته خانواده Qwen3 [۴۰، ۴۱] به کار گرفته شده است.

تاریخچه، انگیزه و ضرورت پیدایش الگوریتم

با گسترش مدل‌های زبانی استدلالی نظیر OpenAI o1 [۴۲] و DeepSeek-R1 [۴۳]، نقش یادگیری تقویتی در مقیاس‌پذیری زمان تفکر (Test-Time Compute) و تولید زنجیره‌های طولانی استدلال (Long Chain-of-Thought) برای حل مسائل ریاضی و برنامه‌نویسی رقابتی اثبات گردید.

پیش از ابداع GSPO، روند توسعه الگوریتم‌های یادگیری تقویتی در مدل‌های زبانی با چالش‌های اساسی روبرو بود:

- **محدودیت‌های PPO [۲۰]:** الگوریتم PPO نیازمند یک مدل منتقد یا ارزش (Value/Critic Model) مجزا برای برآورد مزیت در هر توکن است. این مدل علاوه بر تحمیل بار حافظه و محاسباتی هم‌اندازه با مدل خط‌مشی اصلی، در پاسخ‌های طولانی استدلالی (چندین هزار توکن) به دلیل انباشت خطای پیش‌بینی، به شدت ناپایدار و غیرقابل اعتماد می‌گردد.
- **ظهور و معضلات الگوریتم GRPO [۳۲]:** الگوریتم GRPO با حذف مدل منتقد و جایگزینی آن با برآورد مزیت نسبی در یک گروه از پاسخ‌ها (Group Relative Advantage)، نیاز به حافظه اضافی را رفع کرد. با این حال، GRPO در آموزش مدل‌های بسیار بزرگ و در استدلال‌های طولانی، مکرراً با پدیده «فروپاشی فاجعه‌بار و غیرقابل بازگشت مدل» (Irreversible Model Collapse) مواجه می‌شود [۴۰، ۴۴]. در صورت وقوع این فروپاشی، هیچ‌گونه دستکاری در ابرپارامترها یا بارگذاری مجدد چک‌پوینت‌ها کمکی به همگرایی مجدد نخواهد کرد.

نویسندگان مقاله GSPO ریشه این ناپایداری در GRPO را در دو نقص تئوریک شناسایی کردند:

۱. **نقض مبانی ریاضی نمونه‌برداری اهمیت (Importance Sampling):** اصل نمونه‌برداری اهمیت برای تخمین امید ریاضی یک تابع $f(z)$ تحت توزیع هدف π_{tar} با استفاده از توزیع رفتاری π_{beh} به صورت زیر بیان می‌شود:

$$\mathbb{E}_{z \sim \pi_{tar}}[f(z)] = \mathbb{E}_{z \sim \pi_{beh}} \left[\frac{\pi_{tar}(z)}{\pi_{beh}(z)} f(z) \right] \approx \frac{1}{N} \sum_{k=1}^N \frac{\pi_{tar}(z^{(k)})}{\pi_{beh}(z^{(k)})} f(z^{(k)}) \quad (۲۶)$$

این رابطه ریاضی از نظر آماری تنها در صورتی معتبر و بدون انحراف است که میانگین‌گیری روی تعداد زیادی نمونه ($N \gg 1$) از توزیع رفتاری صورت پذیرد. در حالی که GRPO نسبت اهمیت $\frac{\pi_{\theta}(y_{i,t}|x,y_{i,<t})}{\pi_{\theta_{old}}(y_{i,t}|x,y_{i,<t})}$ را برای هر تک‌توکن t و با تنها یک نمونه تکی ($N = 1$) اعمال می‌کند. این کار به جای تصحیح انحراف توزیع، نویز ضرب‌شونده با واریانس بسیار بالا را وارد گرادیان کرده که با طولانی‌تر شدن زنجیره استدلال انباشته شده و مدل را نابود می‌سازد.

۲. **عدم انطباق واحد بهینه‌سازی و واحد پاداش (Mismatch Principle):** پاداش ارزیاب $r(x, y)$ به کل توالی پاسخ اعطا می‌شود نه به تک‌تک توکن‌ها. بنابراین، اعمال تصحیح خارج از خط‌مشی (Off-Policy Correction) و عملگر برش در سطح توکن‌های مجزا، فرمول‌بندی نادرست و ناسازگاری ایجاد می‌کند.

مبانی نظری و اشتقاق‌های کامل ریاضی GSPO

در یک مدل زبانی خودبازگشتی، درستی‌نمایی (Likelihood) یک پاسخ $y = (y_1, y_2, \dots, y_{|y|})$ به ازای پرسش ورودی x تحت خط‌مشی π_θ برابر است با:

$$\pi_\theta(y|x) = \prod_{t=1}^{|y|} \pi_\theta(y_t|x, y_{<t}) \quad (۲۷)$$

الگوریتم GSPO، تابع هدف بهینه‌سازی را مستقیماً در سطح توالی فرمول‌بندی می‌کند:

$$\mathcal{J}_{\text{GSPO}}(\theta) = \mathbb{E}_{x \sim \mathcal{D}, \{y_i\}_{i=1}^G \sim \pi_{\theta_{\text{old}}}(\cdot|x)} \left[\frac{1}{G} \sum_{i=1}^G \min \left(s_i(\theta) \hat{A}_i, \text{clip}(s_i(\theta), 1 - \varepsilon, 1 + \varepsilon) \hat{A}_i \right) \right] \quad (۲۸)$$

که در آن G اندازه گروه پاسخ‌های هم‌زمان به ازای هر پرسش بوده و مزیت گروهی $\hat{A}_i$ بر اساس امتیاز پاداش تاییدکننده $r(x, y_i) \in [0, 1]$ به صورت زیر نرمال‌سازی می‌شود:

$$\hat{A}_i = \frac{r(x, y_i) - \text{mean}(\{r(x, y_i)\}_{i=1}^G)}{\text{std}(\{r(x, y_i)\}_{i=1}^G)} \quad (۲۹)$$

نسبت اهمیت توالی $s_i(\theta)$ بر اساس مفهوم درستی‌نمایی توالی با نرمال‌سازی طولی (Length-Normalized Sequence Likelihood) [۴۵] تعریف می‌شود:

$$s_i(\theta) \triangleq \left(\frac{\pi_\theta(y_i|x)}{\pi_{\theta_{\text{old}}}(y_i|x)} \right)^{\frac{1}{|y_i|}} = \exp \left(\frac{1}{|y_i|} \sum_{t=1}^{|y_i|} \log \frac{\pi_\theta(y_{i,t}|x, y_{i,<t})}{\pi_{\theta_{\text{old}}}(y_{i,t}|x, y_{i,<t})} \right) \quad (۳۰)$$

اثبات گام‌به‌گام اشتقاق گرادیان GSPO: با صرف‌نظر از عملگر غیرخطی برش جهت بررسی گرادیان بدون مرز، گرادیان تابع هدف نسبت به پارامترهای θ به صورت زیر محاسبه می‌شود:

$$\begin{aligned} \nabla_\theta \mathcal{J}_{\text{GSPO}}(\theta) &= \nabla_\theta \mathbb{E}_{x, \{y_i\}_{i=1}^G} \left[\frac{1}{G} \sum_{i=1}^G s_i(\theta) \hat{A}_i \right] \\ &= \mathbb{E}_{x, \{y_i\}_{i=1}^G} \left[\frac{1}{G} \sum_{i=1}^G \hat{A}_i \nabla_\theta s_i(\theta) \right] \end{aligned} \quad (۳۱)$$

با توجه به اینکه برای هر تابع مثبت $f(\theta)$ داریم $\nabla_\theta \log f(\theta) = \frac{\nabla_\theta f(\theta)}{f(\theta)}$ ، مشتق نسبت اهمیت توالی برابر است با:

$$\nabla_\theta s_i(\theta) = s_i(\theta) \nabla_\theta \log s_i(\theta) \quad (۳۲)$$

با اعمال لگاریتم بر طرفین معادله (۳۰):

$$\log s_i(\theta) = \frac{1}{|y_i|} \sum_{t=1}^{|y_i|} [\log \pi_\theta(y_{i,t}|x, y_{i,<t}) - \log \pi_{\theta_{\text{old}}}(y_{i,t}|x, y_{i,<t})] \quad (۳۳)$$

از آنجا که جمله مربوط به θ_{old} مستقل از θ است، مشتق آن صفر می‌شود:

$$\nabla_\theta \log s_i(\theta) = \frac{1}{|y_i|} \sum_{t=1}^{|y_i|} \nabla_\theta \log \pi_\theta(y_{i,t}|x, y_{i,<t}) \quad (۳۴)$$

بنابراین، فرمول بسته نهایی گرادیان GSPO حاصل می‌شود:

$$\nabla_{\theta} \mathcal{J}_{\text{GSPO}}(\theta) = \mathbb{E}_{x, \{y_i\}_{i=1}^G} \left[\frac{1}{G} \sum_{i=1}^G \left(\frac{\pi_{\theta}(y_i|x)}{\pi_{\theta_{\text{old}}}(y_i|x)} \right)^{\frac{1}{|y_i|}} \hat{A}_i \cdot \frac{1}{|y_i|} \sum_{t=1}^{|y_i|} \nabla_{\theta} \log \pi_{\theta}(y_{i,t}|x, y_{i,<t}) \right] \quad (35)$$

در مقام مقایسه، گرادیان الگوریتم GRPO به صورت زیر است:

$$\nabla_{\theta} \mathcal{J}_{\text{GRPO}}(\theta) = \mathbb{E}_{x, \{y_i\}_{i=1}^G} \left[\frac{1}{G} \sum_{i=1}^G \hat{A}_i \cdot \frac{1}{|y_i|} \sum_{t=1}^{|y_i|} \left(\frac{\pi_{\theta}(y_{i,t}|x, y_{i,<t})}{\pi_{\theta_{\text{old}}}(y_{i,t}|x, y_{i,<t})} \right) \nabla_{\theta} \log \pi_{\theta}(y_{i,t}|x, y_{i,<t}) \right] \quad (36)$$

تحلیل مقایسه‌ای دو گرادیان: در GRPO (معادله (36))، گرادیان هر توکن با یک وزن نابرابر و تصادفی $\frac{\pi_{\theta}(y_{i,t})}{\pi_{\theta_{\text{old}}}(y_{i,t})}$ مقیاس‌بندی می‌شود که این نوسانات نامتعادل در طول هزاران گام به فروپاشی مدل می‌انجامد. اما در GSPO (معادله (35))، تمامی توکن‌های درون یک پاسخ با یک ضریب کاملاً همگن و یکنواخت $(s_i(\theta) \frac{\hat{A}_i}{|y_i|})$ وزن‌دهی می‌شوند که عامل اصلی ثبات بی‌نظیر این الگوریتم است.

گونه تعمیم‌یافته برای توکن‌ها (GSPO-token Variant)

برای سناریوهایی نظیر یادگیری تقویتی چندنوبته (Multi-turn RL) یا استفاده از مدل‌های پاداش فرآیندی (PRM) که نیازمند مزیت‌های متفاوت برای هر گام یا توکن $(\hat{A}_{i,t})$ هستیم، گونه GSPO-token با بهره‌گیری از عملگر سد گرادیان (Stop-Gradient یا $\text{sg}[\cdot]$) معرفی شده است:

$$\mathcal{J}_{\text{GSPO-token}}(\theta) = \mathbb{E} \left[\frac{1}{G} \sum_{i=1}^G \frac{1}{|y_i|} \sum_{t=1}^{|y_i|} \min \left(s_{i,t}(\theta) \hat{A}_{i,t}, \text{clip}(s_{i,t}(\theta), 1 - \varepsilon, 1 + \varepsilon) \hat{A}_{i,t} \right) \right] \quad (37)$$

که در آن نسبت توکن با ساختار زیر تعریف می‌شود:

$$s_{i,t}(\theta) \triangleq \text{sg}[s_i(\theta)] \cdot \frac{\pi_{\theta}(y_{i,t}|x, y_{i,<t})}{\text{sg}[\pi_{\theta}(y_{i,t}|x, y_{i,<t})]} \quad (38)$$

از آنجا که عبارت کسری از نظر مقداری دقیقاً برابر با 1 است، مقدار عددی $s_{i,t}(\theta) = s_i(\theta)$ بوده و شرط برش در سطح کل توالی حفظ می‌شود. در زمان مشتق‌گیری، گرادیان مستقیماً روی توکن t اثر می‌گذارد:

$$\nabla_{\theta} \mathcal{J}_{\text{GSPO-token}}(\theta) = \mathbb{E} \left[\frac{1}{G} \sum_{i=1}^G \left(\frac{\pi_{\theta}(y_i|x)}{\pi_{\theta_{\text{old}}}(y_i|x)} \right)^{\frac{1}{|y_i|}} \cdot \frac{1}{|y_i|} \sum_{t=1}^{|y_i|} \hat{A}_{i,t} \nabla_{\theta} \log \pi_{\theta}(y_{i,t}|x, y_{i,<t}) \right] \quad (39)$$

در حالتی که مزیت تمام توکن‌ها یکسان باشد ($\hat{A}_{i,t} = \hat{A}_i$)، این گرادیان دقیقاً و به صورت تحلیلی با گرادیان GSPO اصلی هم‌ارز می‌گردد.

تحلیل‌های تئوری اطلاعات، آمار و دینامیک مدل‌های MoE

۱. **کنترل واریانس و واگرایی KL:** بر اساس تئوری اطلاعات، نسبت درستی‌نمایی ضرب‌شونده بدون نرمال‌سازی طولی دارای واریانس متناسب با طول پاسخ است ($\text{Var} \propto \mathcal{O}(|y|)$). با اعمال میانگین هندسی در توان $\frac{1}{|y|}$ ، واریانس نسبت اهمیت به صورت $\mathcal{O}(1/|y|)$ میرا شده و کران واگرایی اطلاعاتی میان سیاست جدید و قدیم کنترل می‌شود.

۲. **تثبیت دینامیک آموزش در معماری‌های ترکیبی از متخصصان (MoE):** در مدل‌های MoE نظیر Qwen3-30B-A3B با ۴۸ لایه، پس از هر به‌روزرسانی گرادیان، تخصیص حدود ۱۰٪ از روترهای متخصصان تغییر می‌کند (Expert-Activation Volatility). این پدیده باعث نوسان شدید در درستی‌نمایی محلی توکن‌ها شده و آموزش GRPO را به شکست قطعی می‌کشاند، مگر آنکه از روش پرهزینه «بازپخش مسیریابی» (Routing Replay) برای اجبار به استفاده از مسیرهای قدیمی استفاده شود. GSPO به دلیل تمرکز بر درستی‌نمایی کل توالی و عدم حساسیت به تغییرات جابجایی روترهای محلی، نیاز به Routing Replay را کاملاً منسوخ کرده و ظرفیت کامل مدل را بدون افت سرعت آزاد می‌سازد.

۳. **بهینه‌سازی زیرساخت آموزش (Infrastructure):** تفاوت‌های دقت ممیز شناور میان موتورهای استنتاج (vLLM / SGLang) و موتورهای آموزش (Megatron-LM) در سطح تک‌توکن‌ها خطاساز است. GSPO به دلیل پایداری در سطح توالی، به مدل اجازه می‌دهد تا مستقیماً لاگ‌احتمالات خروجی از موتور استنتاج را بدون نیاز به محاسبه مجدد (Recomputation) در موتور آموزش استفاده کند.

دیاگرام معماری و جریان داده‌های الگوریتم

شکل ۳ ساختار جامع خط لوله آموزش، محاسبات نسبت توالی و تفاوت بنیادین جریان داده در الگوریتم GSPO در مقایسه با روش‌های پیشین را نمایش می‌دهد.

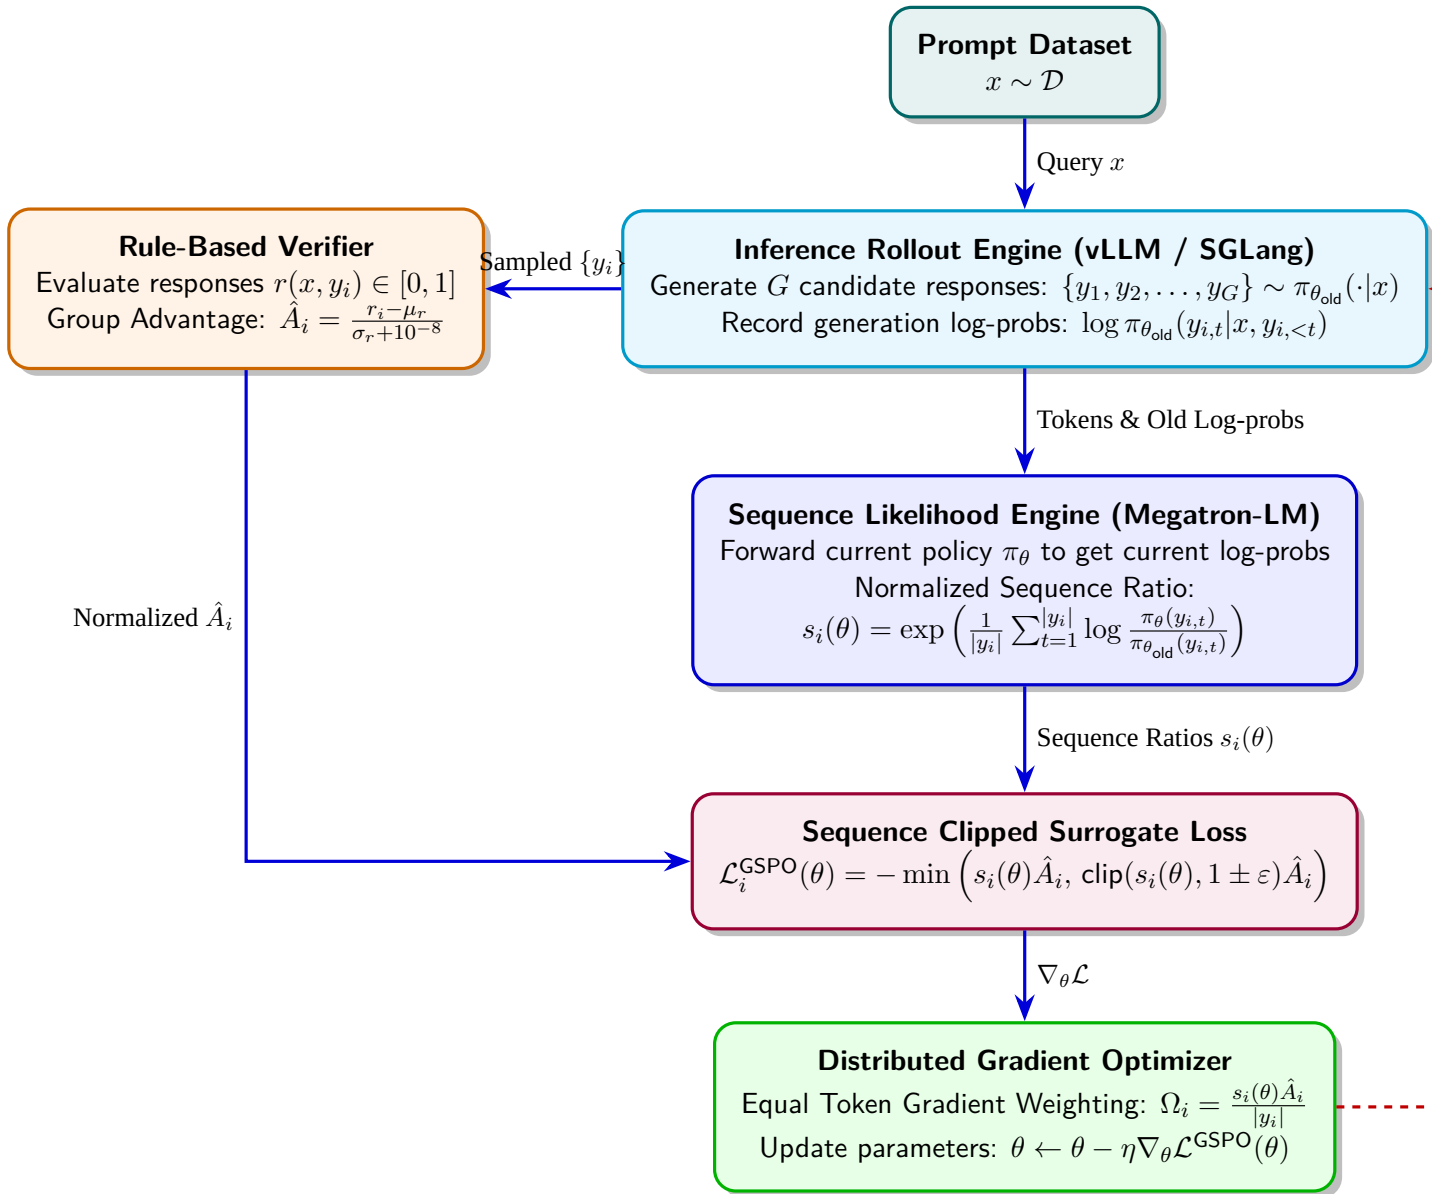
شبه‌کد الگوریتم GSPO

شبه‌کد رسمی و استاندارد پیاده‌سازی مقیاس‌پذیر الگوریتم GSPO در الگوریتم ۳ ارائه شده است:

Algorithm 3 Group Sequence Policy Optimization (GSPO)

```

1: Input: Initial actor policy parameters  $\theta_0$ , verifier reward function  $r(x, y)$ , group size  $G$ , clipping threshold  $\varepsilon$ , learning rate  $\eta$ , number of mini-batches  $K$ .
2: for iteration = 1, 2, ... do
3:   Sample a batch of queries  $\{x_j\}_{j=1}^B \sim \mathcal{D}$ .
4:   Set behavior policy  $\theta_{\text{old}} \leftarrow \theta$ .
5:   Initialize rollout buffer  $\mathcal{B} \leftarrow \emptyset$ .
6:   for each query  $x \in \{x_j\}_{j=1}^B$  do
7:     Generate  $G$  responses  $\{y_i\}_{i=1}^G \sim \pi_{\theta_{\text{old}}}(\cdot|x)$  using inference engine.
8:     Compute scalar rewards  $r_i = r(x, y_i)$  for  $i \in \{1, \dots, G\}$ .
9:     Compute group advantage:  $\hat{A}_i = \frac{r_i - \text{mean}(\{r_k\})}{\text{std}(\{r_k\}) + 10^{-8}}$ .
10:    for  $i = 1, \dots, G$  do
11:      Store rollout record  $(x, y_i, \hat{A}_i, \{\log \pi_{\theta_{\text{old}}}(y_{i,t}|x, y_{i,<t})\}_{t=1}^{|y_i|})$  in  $\mathcal{B}$ .
12:    end for
13:  end for
14:  Partition buffer  $\mathcal{B}$  into  $K$  mini-batches  $\{\mathcal{B}_m\}_{m=1}^K$ .
15:  for each mini-batch  $\mathcal{B}_m$  do
16:    Forward current policy  $\pi_\theta$  to get current log-probabilities  $\log \pi_\theta(y_{i,t}|x, y_{i,<t})$ .
17:    Compute length-normalized sequence importance ratio for each sample:
18:     $s_i(\theta) = \exp\left(\frac{1}{|y_i|} \sum_{t=1}^{|y_i|} (\log \pi_\theta(y_{i,t}|x, y_{i,<t}) - \log \pi_{\theta_{\text{old}}}(y_{i,t}|x, y_{i,<t}))\right)$ .
19:    Compute sequence clipped surrogate loss:
20:     $\mathcal{L}(\theta) = -\frac{1}{|\mathcal{B}_m|} \sum_{i \in \mathcal{B}_m} \min\left(s_i(\theta)\hat{A}_i, \text{clip}(s_i(\theta), 1 - \varepsilon, 1 + \varepsilon)\hat{A}_i\right)$ .
21:    Perform backward pass and parameter update:
22:     $\theta \leftarrow \theta - \eta \nabla_\theta \mathcal{L}(\theta)$ .
23:  end for
24: end for
```



شکل ۳: دیاگرام جامع معماری خط لوله آموزش، محاسبه نسبت اهمیت توالی با نرمال‌سازی طولی و به‌روزرسانی گرادینان همگن در الگوریتم GSPO.

نتایج تجربی و ارزیابی بنچمارک‌ها

ارزیابی تجربی GSPO بر روی مدل پایه Qwen3-30B-A3B-Base در مقایسه با GRPO در بنچمارک‌های استاندارد استدلالی، برنامه‌نویسی و ریاضی در جدول ۸ آورده شده است.

جدول ۸: مقایسه عملکرد و پایداری الگوریتم‌های GRPO و GSPO بر روی مدل Qwen3-30B-A3B (برگرفته از [۳۹]).

الگوریتم یادگیری تقویتی	AIME ۲۴' (Pass@1)	LiveCodeBench (Pass@1)	CodeForces (Elo)	پایداری در آموزش MoE
GRPO (بدون Replay)	ناموفق (فروپاشی)	ناموفق (فروپاشی)	ناموفق (فروپاشی)	کاملاً ناپایدار
GRPO (با Replay)	۲٪.۷۷	۴٪.۶۳	۱۹۲۰	نیازمند سربرار حافظه
GSPO (رویکرد پیشنهادی)	۶٪.۸۲	۱٪.۶۸	۲۰۶۵	پایداری کامل و ذاتی

پارادوکس کسر توکن‌های برش‌خورده (Clipping Fraction Paradox): جدول ۹ مقایسه جالب میانگین توکن‌های برش‌خورده را نشان می‌دهد. با وجود اینکه GSPO حدود دو مرتبه بزرگی توکن‌های بیشتری را برش می‌زند (۱۵٪ در برابر ۱۳٪.۰)، راندمان نمونه‌ای بسیار بالاتری ارائه می‌دهد؛ امری که نشان می‌دهد گرادیان‌های توکنی GRPO سراسر نویز مخرب بوده‌اند.

جدول ۹: مقایسه کسر توکن‌های برش‌خورده در طول آموزش [۳۹].

شاخص مقایسه‌ای	الگوریتم GRPO	الگوریتم GSPO
کسر توکن‌های برش‌خورده (Clipping Fraction)	۱۳٪.۰	۱۵۰۰.۰ (۱۵٪.۰)
نحوه اعمال برش	سطح تک‌توکن	سطح کل توالی
راندمان بهره‌وری نمونه (Sample Efficiency)	پایین (آنباشت نویز)	بسیار بالا

ابریارمترهای استاندارد گزارش‌شده در مقاله

جدول ۱۰ ابریارمترهای بهینه‌سازی آموزش GSPO را در مقایسه با GRPO نشان می‌دهد:

جدول ۱۰: ابریارمترهای استاندارد آموزش RL برای مدل Qwen3-30B-A3B.

مقدار در الگوریتم GSPO	ابریارمتر
3×10^{-4} , 4×10^{-4}	محدوده برش چپ و راست (ϵ_{left} , ϵ_{right})
0.20, 0.27	محدوده برش در الگوریتم پایه GRPO
۸	اندازه گروه پاسخ‌ها به ازای پرسش (G)
۴	تعداد مینی‌بچ‌ها به ازای هر دسته داده‌برداری (K)
$s_i(\theta) \hat{A}_i / y_i $	نوع توزیع وزن گرادیان درون توالی
خیر (حذف کامل)	نیاز به استراتژی Routing Replay

جمع‌بندی

الگوریتم GSPO با حل ناسازگاری ریاضی نمونه‌برداری اهمیت و اعمال وزن‌دهی و برش همگن در سطح کل توالی، معضل فروپاشی فاجعه‌بار آموزش را برای همیشه برطرف ساخته است. این الگوریتم با حذف نیاز به Routing Replay در مدل‌های تنک MoE و افزایش چشمگیر راندمان محاسباتی در زیرساخت‌های توزیع‌شده، به عنوان استاندارد نوین مقیاس‌پذیری یادگیری تقویتی در مدل‌های زبانی استدلالی شناخته می‌شود.

۴.۷ الگوریتم بهینه‌سازی خط‌مشی با برش مجزا و نمونه‌برداری پویا Decoupled Clip and Dynamic Sampling Policy Optimization - DAPO

الگوریتم DAPO که در سال ۲۰۲۵ توسط محققان آزمایشگاه ByteDance Seed و دانشگاه تسینگ‌هاوا (Tsinghua AIR) معرفی شد [۴۶]، یک سامانه پیشرفته، مقیاس‌پذیر و کاملاً متن‌باز برای یادگیری تقویتی در مدل‌های زبانی استدلال‌گر بزرگ (Reasoning LLMs) به شمار می‌رود. این الگوریتم با برطرف کردن موانع اساسی در سناریوهای استدلال با زنجیره تفکر طولانی (Long Chain-of-Thought - Long-CoT)، موفق شد بر پایه مدل پایه Qwen2.5-32B [۴۷] به دقت ۵۰٪ در بنچمارک المپیاد ریاضی AIME 2024 دست یابد و با مصرف تنها ۵۰٪ از گام‌های آموزشی، از مدل پیشروی DeepSeek-R1-Zero- [۴۸] Qwen-32B پیشی بگیرد.

تاریخچه، انگیزه و ضرورت پیدایش الگوریتم

با ظهور پارادایم افزایش محاسبات در زمان استنتاج (Test-Time Compute Scaling) توسط مدل‌هایی همچون OpenAI o1 [۴۲] و DeepSeek-R1 [۴۸]، استدلال مبتنی بر زنجیره تفکر طولانی به ابزار اصلی حل مسائل ریاضیات پیشرفته و برنامه‌نویسی مبدل گشت. با این وجود، به دلیل پنهان نگه‌داشتن جزئیات فنی و ترفندهای حیاتی پایدارسازی آموزش در گزارش‌های فنی این مدل‌ها، تلاش‌های مستقل جامعه متن‌باز برای بازتولید این نتایج با الگوریتم‌های رایج نظیر GRPO [۳۲] و PPO [۲۰] با ناکامی مواجه شد (دستیابی به تنها ۳۰٪ در AIME).

تحلیل‌های عمیق نشان داد که الگوریتم‌های سنتی در سناریوی استدلال‌های طولانی از چهار چالش بحرانی رنج می‌برند:

- **فروپاشی آنتروپی (Entropy Collapse):** محدودیت بازه برش استاندارد، مانع ارتقای احتمال توکن‌های نادر اما حیاتی برای اکتشاف شده و مدل را به سرعت دچار دترمینیسم زودهنگام و پاسخ‌های یکنواخت می‌کند.
- **افت سیگنال گرادیان (Vanishing Gradient in Extreme Samples):** در پرامپت‌هایی که تمام خروجی‌های گروه درست یا همگی غلط بودند، واریانس پاداش صفر شده و گرادیان آموزشی ناپدید می‌گشت که به کاهش اندازه موثر دسته و افت شدید نسبت سیگنال به نویز (SNR) می‌انجامید.
- **ناهمگونی وزن توکن‌ها (Sample vs. Token Level Imbalance):** میانگین‌گیری در سطح نمونه در روش‌های پیشین باعث می‌شد که توکن‌های مفید در پاسخ‌های طولانی سهم گرادیان اندکی دریافت کنند و الگوهای تکراری مخرب و هذیان‌های طویل (Repetitive Gibberish) به اندازه کافی جریمه نشوند.
- **نویز ناشی از برش سخت پاسخ‌ها (Truncation Reward Noise):** جریمه کردن پاسخ‌های درستی که صرفاً به سقف طول مجاز برخورد کرده بودند، سیگنال‌های گمراه‌کننده‌ای به مدل القا می‌کرد.

الگوریتم DAPO برای حل جامع این معضلات، چهار نوآوری اساسی را در قالب یک چارچوب بهینه‌سازی مقیاس‌پذیر ارائه داد.

مبانی نظری و اشتقاق‌های کامل ریاضی

فرض کنید یک توالی کامل تولیدشده به صورت $\tau = (q, o_1, o_2, \dots, o_T)$ نمایش داده شود که در آن q پرسش و o_t توکن‌های خروجی تحت خط‌مشی پارامتریزه π_θ هستند. هدف بهینه‌سازی بیشینه‌سازی

امید ریاضی پاداش است:

$$J(\theta) = \mathbb{E}_{\tau \sim \pi_\theta} [R(\tau)] = \int P(\tau; \theta) R(\tau) d\tau \quad (۴۰)$$

با مشتق‌گیری نسبت به بردار پارامترها θ طبق قاعده لاینیتس و اعمال اتحاد لگاریتمی تابع امتیاز $(\nabla_\theta P = P \nabla_\theta \log P)$:

$$\nabla_\theta J(\theta) = \int \nabla_\theta P(\tau; \theta) R(\tau) d\tau = \int P(\tau; \theta) \nabla_\theta \log P(\tau; \theta) R(\tau) d\tau = \mathbb{E}_{\tau \sim \pi_\theta} [\nabla_\theta \log P(\tau; \theta) R(\tau)] \quad (۴۱)$$

با توجه به ساختار خودبازگشتی مدل‌های زبانی $(P(\tau; \theta) = P(q) \prod_{t=1}^{|o|} \pi_\theta(o_t | q, o_{<t}))$ و کسر خط مبنای مستقل از عمل جهت کاهش واریانس، گرادینان بر حسب تابع مزیت $\hat{A}_t$ استخراج می‌شود:

$$\nabla_\theta J(\theta) = \mathbb{E}_{q \sim \mathcal{D}, o \sim \pi_\theta(\cdot | q)} \left[\sum_{t=1}^{|o|} \nabla_\theta \log \pi_\theta(o_t | q, o_{<t}) \hat{A}_t \right] \quad (۴۲)$$

با استفاده از نمونه‌برداری ترجیحی (Importance Sampling) برای استفاده مجدد از داده‌های جمع‌آوری‌شده توسط خط‌مشی قدیمی $\pi_{\theta_{\text{old}}}$ ، نسبت احتمالاتی برای توکن t به صورت زیر تعریف می‌شود:

$$r_{i,t}(\theta) = \frac{\pi_\theta(o_{i,t} | q, o_{i,<t})}{\pi_{\theta_{\text{old}}}(o_{i,t} | q, o_{i,<t})} \quad (۴۳)$$

در الگوریتم **GRPO** [۳۲]، برای هر پرسش q یک گروه شامل G پاسخ $\{o_i\}_{i=1}^G$ تولید شده و مزیت هر نمونه به صورت نرمال‌سازی درون‌گروهی بدون شبکه منتقد محاسبه می‌شود:

$$\hat{A}_{i,t} = \frac{R_i - \text{mean}(\{R_i\}_{i=1}^G)}{\text{std}(\{R_i\}_{i=1}^G) + \epsilon_{\text{var}}} \quad (۴۴)$$

حذف جریمه واگرایی KL: برخلاف روش‌های رایج RLHF که عبارت جریمه $-\beta D_{\text{KL}}(\pi_\theta \parallel \pi_{\text{ref}})$ را برای جلوگیری از انحراف مدل تحمیل می‌کنند، در استدلال‌های طولانی، توزیع مدل برای یادگیری راهبردهای جدید باید بتواند به طور چشمگیری از مدل پایه اولیه فاصله بگیرد؛ لذا در **DAPO** ترم واگرایی KL به طور کامل حذف شده است ($\beta = 0$).

فرمولاسیون ریاضی و چهار نوآوری بنیادین DAPO

تابع هدف سراسری الگوریتم **DAPO** به صورت زیر تعریف می‌شود:

$$J_{\text{DAPO}}(\theta) = \mathbb{E}_{(q,a) \sim \mathcal{D}, \{o_i\}_{i=1}^G \sim \pi_{\theta_{\text{old}}}} \left[\frac{1}{\sum_{i=1}^G |o_i|} \sum_{i=1}^G \sum_{t=1}^{|o_i|} \min \left(r_{i,t}(\theta) \hat{A}_{i,t}, \text{clip}(r_{i,t}(\theta), 1 - \epsilon_{\text{low}}, 1 + \epsilon_{\text{high}}) \hat{A}_{i,t} \right) \right] \quad (۴۵)$$

$$\text{s.t.} \quad 0 < \sum_{i=1}^G \mathbb{I}(\text{is_equivalent}(a, o_i)) < G \quad (۴۶)$$

چهار رکن اساسی این فرمولاسیون عبارتند از:

۱. **برش نامتقارن به سمت بالا (Clip-Higher):** در برش متقارن کلاسیک ($\epsilon = 0.2$)، بیشینه نسبت احتمالاتی مجاز برای توکن‌های با مزیت مثبت برابر با $1 + \epsilon = 1.2$ است. برای توکن‌های استثنای

با احتمال اولیه بالا (مثلاً $\pi_{old} = 0.9$) بیشینه احتمال مجاز 1.08 بوده که اجازه رشد تا نزدیکی ۱ را می‌دهد. اما برای توکن‌های اکتشافی نادر (مثلاً $\pi_{old} = 0.01$)، سقف رشد مجاز تنها 0.012 است ($\Delta p = +0.002$). الگوریتم DAPO با تفکیک آستانه‌ها و قرار دادن $\varepsilon_{high} = 0.28$ و $\varepsilon_{low} = 0.20$ ، فضای کافی برای ارتقای توکن‌های اکتشافی فراهم می‌سازد و مانع فروپاشی آنتروپی می‌شود.

۲. نمونه‌برداری پویا (Dynamic Sampling): اگر تمامی نمونه‌های گروه برای یک پرامپت درست یا همگی غلط باشند، $\hat{A}_{i,t} = 0$ شده و گرادیان آموزشی آن پرامپت صفر می‌شود. DAPO با اعمال شرط قید در حین گردآوری داده، نمونه‌برداری را تا پر شدن کامل بافر با دسته‌های دارای گرادیان موثر ($0 < \text{Correct} < G$) ادامه می‌دهد که این امر نسبت سیگنال به نویز گرادیان را در بالاترین سطح نگه می‌دارد.

۳. تابع اتلاف در سطح توکن (Token-Level Policy Gradient Loss): برخلاف GRPO که ابتدا اتلاف را بر طول هر نمونه $|o_i|$ تقسیم می‌کرد، DAPO نرمال‌سازی را بر مجموع کل توکن‌های گروه ($\sum_{i=1}^G |o_i|$) انجام می‌دهد. این امر موجب می‌شود توکن‌های الگوهای استدلالی بلندمرتبه ارزش‌گذاری عادلانه شده و توکن‌های هذیان‌گونه در پاسخ‌های معیوب به شدت تنبیه شوند.

۴. شکل‌دهی نرم پاداش طول پاسخ (Soft Overlong Punishment): برای جلوگیری از شوک گرادیانی ناشی از برش سخت پاسخ‌ها در طول L_{max} ، یک بازه حفاظتی L_{cache} تعریف شده و جریمه خطی پیوسته‌ای به پاداش درستی اضافه می‌گردد:

$$R_{\text{length}}(y) = \begin{cases} 0 & |y| \leq L_{max} - L_{cache} \\ \frac{(L_{max} - L_{cache}) - |y|}{L_{cache}} & L_{max} - L_{cache} < |y| \leq L_{max} \\ -1 & |y| > L_{max} \end{cases} \quad (۴۷)$$

تحلیل‌های تئوری اطلاعات و آمار ریاضی

آنتروپی شانون خط‌مشی به صورت $\mathcal{H}(\pi_{\theta}(\cdot|s)) = -\sum_{v \in \mathcal{V}} \pi_{\theta}(v|s) \log \pi_{\theta}(v|s)$ تعریف می‌شود. در الگوریتم‌های استاندارد، به دلیل محدودیت شدید رشد احتمالات کوچک، $\mathcal{H} \rightarrow 0$ میل کرده و توزیع احتمالاتی بر روی چند توکن محدود تیز می‌شود. راهبرد Clip-Higher باعث حفظ یک شیب ملایم مثبت در آنتروپی تولیدی در طول آموزش شده و از افت به سمت حالت دترمینستیک جلوگیری می‌نماید. همچنین نسبت سیگنال به نویز گرادیان که با $\text{SNR} = \frac{\|\mathbb{E}[g]\|_2}{\sqrt{\text{Tr}(\text{Cov}(g))}}$ تعریف می‌شود، در حضور نمونه‌برداری پویا به دلیل حذف گرادیان‌های تهی همواره در حالت ماکسیمم باقی می‌ماند.

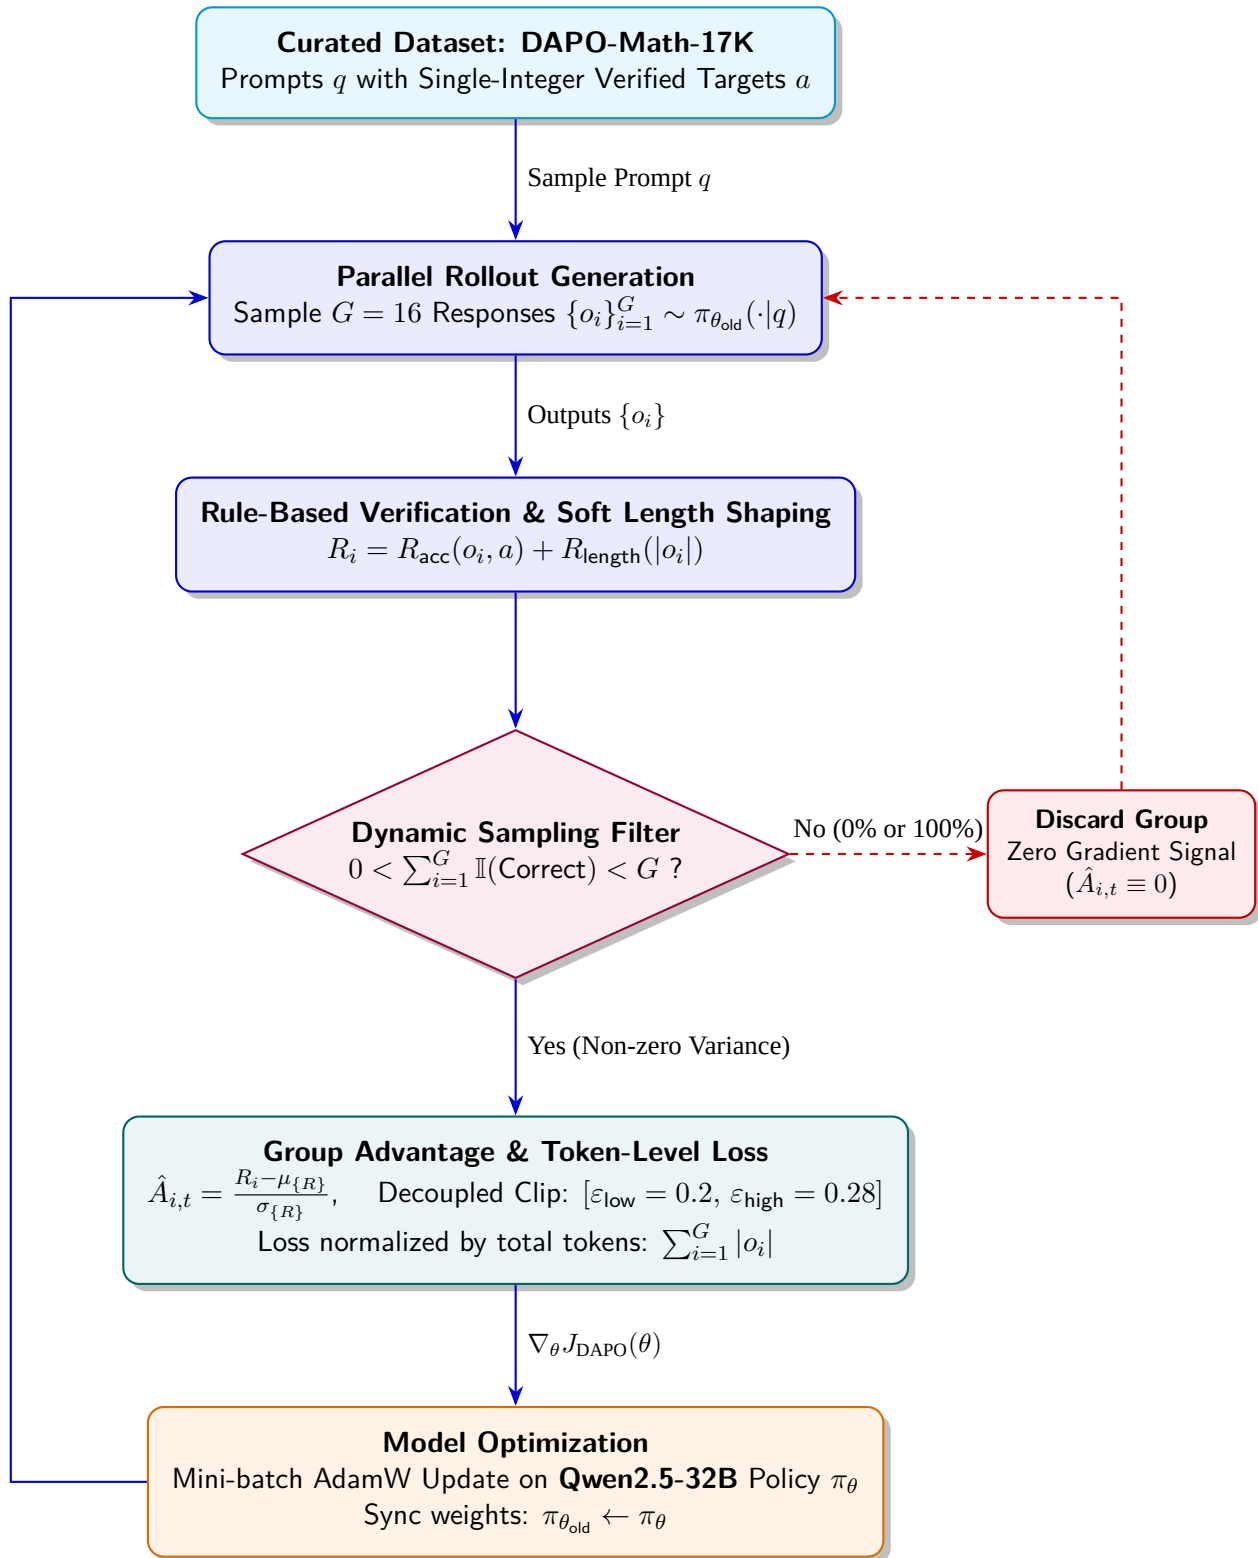
مهندسی داده و تبدیل مجموعه داده (DAPO-Math-17K)

برای بهره‌گیری از پاداش‌های قطعی مبتنی بر قاعده و حذف خطاهای ناشی از مفسرهای فرمول‌های ریاضی (Math Parsers)، مجموعه داده DAPO-Math-17K شامل ۱۷ هزار مسئله بازنویسی‌شده ایجاد شده است. در این فرآیند، با استفاده از مدل‌های زبانی و زنجیره تفکر، صورت مسائل به گونه‌ای بازنویسی شده‌اند که خروجی نهایی آن‌ها بدون استثنا یک **عدد صحیح منفرد** باشد؛ امری که ارزیابی پاداش را بر اساس تابع قطعی زیر مقدور می‌سازد:

$$R(\hat{y}, y) = \begin{cases} +1 & \text{is_equivalent}(\hat{y}, y) \\ -1 & \text{otherwise} \end{cases} \quad (۴۸)$$

دیگرام معماری و جریان داده‌های الگوریتم

شکل ۴، ساختار کلی جریان داده، فیلتر نمونه‌برداری پویا، شکل‌دهی پاداش و به‌روزرسانی خط‌مشی را در الگوریتم DAPO نشان می‌دهد.



شکل ۴: دیاگرام جامع جریان داده، نمونه‌برداری پویا، شکل‌دهی طول و بهینه‌سازی توکن‌محور در الگوریتم DAPO.

شبه‌کد الگوریتم DAPO

شبه‌کد کامل مراحل اجرایی الگوریتم DAPO در الگوریتم ۴ ارائه شده است:

Algorithm 4 Decoupled Clip and Dynamic Sampling Policy Optimization (DAPO)

```

1: Input: Initial policy  $\pi_\theta$ , verifiable reward function  $R$ , dataset  $\mathcal{D}$ , thresholds  $\varepsilon_{\text{low}}, \varepsilon_{\text{high}}$ , group size  $G$ , batch capacity  $N$ , update iterations  $\mu$ .
2: for step = 1, ...,  $M$  do
3:   Synchronize behavior policy:  $\pi_{\theta_{\text{old}}} \leftarrow \pi_\theta$ 
4:   Initialize dynamic buffer  $\mathcal{B}_{\text{dyn}} \leftarrow \emptyset$ 
5:   while  $|\mathcal{B}_{\text{dyn}}| < N$  do
6:     Sample a prompt batch  $\mathcal{D}_b \sim \mathcal{D}$ 
7:     for each question-answer pair  $(q, a) \in \mathcal{D}_b$  do
8:       Sample  $G$  independent rollouts  $\{o_i\}_{i=1}^G \sim \pi_{\theta_{\text{old}}}(\cdot|q)$ 
9:       Evaluate correctness count:  $C_q = \sum_{i=1}^G \mathbb{I}(\text{is\_equivalent}(a, o_i))$ 
10:      if  $C_q == 0$  or  $C_q == G$  then
11:        continue  $\triangleright$  Dynamic Sampling: Filter out degenerate zero-variance prompts
12:      end if
13:      for each response  $o_i$  do
14:        Compute length punishment  $R_{\text{length}}(|o_i|)$  via soft linear caching.
15:        Compute total reward  $R_i = R(o_i, a) + R_{\text{length}}(|o_i|)$ .
16:      end for
17:      Compute group statistics:  $\mu_R = \text{mean}(\{R_i\}_{i=1}^G)$ ,  $\sigma_R = \text{std}(\{R_i\}_{i=1}^G)$ .
18:      for each response  $o_i$  do
19:        Compute advantage:  $\hat{A}_{i,t} = (R_i - \mu_R) / (\sigma_R + 10^{-8})$ .
20:        Add tuple  $(q, o_i, \hat{A}_{i,t})$  to  $\mathcal{B}_{\text{dyn}}$ .
21:      end for
22:    end for
23:  end while
24:  for iter = 1, ...,  $\mu$  do
25:    Compute total token count:  $T_{\text{total}} = \sum_{o_i \in \mathcal{B}_{\text{dyn}}} |o_i|$ .
26:    Compute importance ratio:  $r_{i,t}(\theta) = \frac{\pi_\theta(o_{i,t}|q, o_{i,t})}{\pi_{\theta_{\text{old}}}(o_{i,t}|q, o_{i,t})}$ .
27:    Compute Token-Level Clipped Surrogate Loss:
28:     $J_{\text{DAPO}}(\theta) = \frac{1}{T_{\text{total}}} \sum_{i=1}^{|\mathcal{B}_{\text{dyn}}|} \sum_{t=1}^{|o_i|} \min \left( r_{i,t}(\theta) \hat{A}_{i,t}, \text{clip} \left( r_{i,t}(\theta), 1 - \varepsilon_{\text{low}}, 1 + \varepsilon_{\text{high}} \right) \hat{A}_{i,t} \right)$ .
29:    Update policy parameters via AdamW:  $\theta \leftarrow \theta + \alpha \nabla_\theta J_{\text{DAPO}}(\theta)$ .
30:  end for
31: end for
32: Output: Optimized Reasoning Policy  $\pi_\theta$ .

```

نتایج تجربی، تحلیل پویایی آموزش و مطالعات موردی

اثربخشی گام‌به‌گام هر یک از تکنیک‌های پیشنهادی در جدول ۱۱ بر روی بنچمارک AIME 2024 خلاصه شده است:

پدیدار شدن رفتار خوداصلاحی (Emergence of Self-Correction): در طول آموزش با DAPO، رفتارهای بازبینی و خوداصلاحی عمیق بدون داده نظارت‌شده پدیدار گشت. به عنوان مثال در حل یک مسئله ترکیبیاتی، مدل پس از محاسبه مقدار کسری اشتباه $a_4 = 54.75$ برای تعداد افراد، تفکر خود را قطع کرده و بیان می‌کند:

جدول ۱۱: تحلیل ابلیشن و سهم پیشرونده تکنیک‌های DAPO روی مدل Qwen2.5-32B در بنچمارک AIME 2024 [۴۶].

مدل و راهبرد بهینه‌سازی	دقت AIME 2024 (avg@۳۲)
DeepSeek-R1-Zero-Qwen-32B (مرجع پیشین) [۴۸]	۰.۴۷٪
Naive GRPO (خط مبنای استاندارد)	۰.۳۰٪
+ فیلتر کردن پاسخ‌های قطع‌شده (Overlong Filtering)	۰.۳۶٪
+ برش نامتقارن به سمت بالا (Clip-Higher)	۰.۳۸٪
+ جریمه نرم طول پاسخ (Soft Overlong Punishment)	۰.۴۱٪
+ اتلاف در سطح توکن (Token-Level Loss)	۰.۴۲٪
+ نمونه‌برداری پویا (DAPO کامل)	۰.۵۰٪

”Since a_4 , the number of people owning all four items, must be a whole number, our current approach needs to be reconsidered...”

و سپس با بازتعریف متغیرها به پاسخ صحیح عدد صحیح دست می‌یابد.

ابریارمترهای استاندارد گزارش‌شده در مقاله

جدول ۱۲ مقادیر دقیق ابریارمترهای بهینه‌شده برای آموزش DAPO را نمایش می‌دهد:

مقدار	ابریارمتر
Qwen2.5-32B-Base	مدل پایه پیش‌آموزش‌دیده
[۴۹] verl (HybridFlow)	فریم‌ورک محاسباتی
[۵۰] AdamW	بهینه‌ساز
1×10^{-6} (ثابت با ۲۰ گام گرم‌کردن خطی)	نرخ یادگیری (Learning Rate)
۵۱۲	اندازه دسته پرامپت در Rollout
۱۶	تعداد نمونه به ازای هر پرامپت (G)
۵۱۲ (۱۶ گام به‌روزرسانی گرادیان به ازای هر Rollout)	اندازه مینی‌دسته آموزشی
۱۶،۳۸۴ توکن	سقف طول مجاز استدلال (L_{max})
۴،۰۹۶ توکن	بازه حافظه جریمه نرم (L_{cache})
۲۰،۴۸۰ توکن	حداکثر سقف مطلق طول تولید
۲۰.۰	حد آستانه برش پایین (ϵ_{low})
۲۸.۰	حد آستانه برش بالا (ϵ_{high})
دما $T = 1.0$ و $Top-p = 0.7$ روی ۳۲ بار ارزیابی	پارامترهای ارزیابی استنتاج

جمع‌بندی

الگوریتم DAPO با ترکیب چهار مولفه کلیدی Clip-Higher، Dynamic Sampling، Token-Level Loss و Soft Overlong Punishment نشان داد که چالش‌های بازتولید یادگیری تقویتی در استدلال‌های طولانی ناشی از کاستی‌های ظریف در فرمول‌بندی و پویایی‌های بهینه‌سازی است. انتشار متن‌باز کدها، معماری و پایگاه داده تبدیل‌شده DAPO-Math-17K، زیرساختی پایدار و تکرارپذیر را برای پژوهش‌های آینده در زمینه توسعه مدل‌های هوش مصنوعی استدلال‌گر در مقیاس بزرگ فراهم آورده است.

۵.۷ الگوریتم بهینه‌سازی خط‌مشی تطبیقی نرم (Soft Adaptive Pol-icy Optimization - SAPO)

الگوریتم SAPO که در اواخر سال ۲۰۲۵ توسط تیم Qwen در شرکت علی‌بابا (Alibaba Inc.) معرفی شد [۵۱]، یکی از پیشرفته‌ترین و پایدارترین روش‌های بهینه‌سازی خط‌مشی در مقیاس بزرگ برای مدل‌های زبانی استدلال‌گر (Reasoning LLMs) و مدل‌های چندوجهی (Vision-Language Models) به شمار می‌رود. این الگوریتم با بازنگری بنیادین در مکانیزم برش سخت (Hard Clipping) در روش‌های پیشین گروهی نظیر GRPO [۳۲] و GSPO [۵۲]، یک دروازه‌بندی نرم کنترل‌شده با دما (Temperature-Controlled Soft Gate) به همراه طراحی دمای نامتقارن برای گرادیان‌های مثبت و منفی معرفی می‌کند که مانع از فروپاشی زود هنگام آموزش (Early Training Collapse) شده و بهره‌وری نمونه‌ها را به حداکثر می‌رساند.

تاریخچه، انگیزه و ضرورت پیدایش الگوریتم

با گسترش آموزش یادگیری تقویتی در مدل‌های زبانی بزرگ برای انجام استدلال‌های طولانی ریاضی، برنامه‌نویسی و منطقی [۴۲، ۵۳، ۵۴]، روش‌های مبتنی بر بهینه‌سازی گروهی (Group-based Policy Optimization) به عنوان استاندارد کارآمد جایگزین روش‌های کلاسیک نظیر PPO شدند:

- **معضل روش‌های برش سخت در سطح توکن (GRPO):** الگوریتم GRPO [۳۲] با حذف مدل نقاد (Critic) و نرمال‌سازی پاداش‌ها در یک گروه از پاسخ‌ها، هزینه محاسباتی را به شدت کاهش داد. با این حال، استفاده از تابع برش ناپیوسته در سطح توکن باعث ایجاد رفتار «همه یا هیچ» شد؛ به طوری که توکن‌هایی با نسبت اهمیت خارج از بازه $[1 - \epsilon, 1 + \epsilon]$ گرادیان صفر دریافت کرده و سیگنال‌های یادگیری ارزشمند از بین می‌رفتند.
- **معضل روش‌های برش در سطح توالی (GSPO):** الگوریتم GSPO [۵۲] برش را به میانگین هندسی نسبت‌های کل توالی اعمال کرد تا واریانس انباشته در توالی‌های طولانی را مهار کند. اما نقطه ضعف اساسی آن شکنندگی در برابر توکن‌های پرت (Outlier Tokens) بود؛ اگر تنها چند توکن ناهمگون در یک توالی وجود داشت، کل توالی بریده شده و گرادیان تمامی توکن‌های مفید درون آن توالی مسدود می‌شد.
- **ناپایداری در مدل‌های ترکیبی از متخصصان (MoE):** در معماری‌های MoE نظیر Qwen3-30B-A3B، به دلیل ناهمگونی مسیریابی توکن‌ها (Routing Heterogeneity) به متخصصان مختلف، واریانس نسبت‌های اهمیت $r_{i,t}$ فوق‌العاده افزایش می‌یابد که این پدیده به ناپایداری‌های شدید و سقوط آموزش در الگوریتم‌های سنتی می‌انجامد.

الگوریتم SAPO برای حل این چالش‌ها، یک ناحیه اطمینان پیوسته، نرم و دیفرانسیل‌پذیر معرفی می‌کند که در شرایط عادی انسجام سطح توالی را حفظ کرده و در صورت وجود توکن‌های پرت، به صورت تطبیقی تنها توکن‌های مخرب را مهار می‌نماید.

مبانی نظری و اشتقاق‌های کامل ریاضی الگوریتم SAPO

یک مدل زبانی خودبازگشت به عنوان خط‌مشی تصادفی π_θ بر روی توالی توکن‌های پاسخ $y = (y_1, y_2, \dots, y_{|y|})$ به ازای پرامپت ورودی $q \sim \mathcal{D}$ به صورت حاصل ضرب احتمال‌های شرطی تجزیه می‌شود:

$$\pi_\theta(y | q) = \prod_{t=1}^{|y|} \pi_\theta(y_t | q, y_{<t}) \quad (۴۹)$$

برای هر پرامپت q ، گروهی متشکل از G پاسخ مستقل $\{y_1, \dots, y_G\}$ از خط‌مشی رفتار $\pi_{\theta_{old}}$ نمونه‌برداری شده و پاداش‌های عددی $\{R_1, \dots, R_G\}$ محاسبه می‌شوند. مقدار مزیت نرمال‌شده گروهی $(\hat{A}_i)$ برای

پاسخ i -ام برابر است با:

$$\hat{A}_{i,t} = \hat{A}_i = \frac{R_i - \text{mean}(\{R_j\}_{j=1}^G)}{\text{std}(\{R_j\}_{j=1}^G) + 10^{-8}} \quad (50)$$

نسبت اهمیت در سطح توکن به صورت زیر تعریف می‌شود:

$$r_{i,t}(\theta) \triangleq \frac{\pi_{\theta}(y_{i,t} \mid q, y_{i,<t})}{\pi_{\theta_{\text{old}}}(y_{i,t} \mid q, y_{i,<t})} \quad (51)$$

تابع هدف بهینه‌سازی در الگوریتم SAPO:

$$J_{\text{SAPO}}(\theta) = \mathbb{E}_{q \sim \mathcal{D}, \{y_i\}_{i=1}^G \sim \pi_{\theta_{\text{old}}}(\cdot \mid q)} \left[\frac{1}{G} \sum_{i=1}^G \frac{1}{|y_i|} \sum_{t=1}^{|y_i|} f_{i,t}(r_{i,t}(\theta)) \hat{A}_{i,t} \right] \quad (52)$$

که در آن تابع دروازه‌بندی نرم کنترل‌شده با دما $f_{i,t}(x)$ به صورت زیر تعریف می‌گردد:

$$f_{i,t}(x) = \sigma(\tau_{i,t}(x - 1)) \cdot \frac{4}{\tau_{i,t}}, \quad \tau_{i,t} = \begin{cases} \tau_{\text{pos}} & \text{if } \hat{A}_{i,t} > 0 \\ \tau_{\text{neg}} & \text{if } \hat{A}_{i,t} \leq 0 \end{cases} \quad (53)$$

در این رابطه، $\sigma(u) = \frac{1}{1+e^{-u}}$ تابع سیگموئید استاندارد است.

محاسبه تحلیلی گرادیان خط‌مشی در SAPO: با اعمال عملگر گرادیان ∇_{θ} به رابطه (52) و استفاده از قاعده زنجیره‌ای:

$$\nabla_{\theta} [f_{i,t}(r_{i,t}(\theta)) \hat{A}_{i,t}] = f'_{i,t}(r_{i,t}(\theta)) \cdot \nabla_{\theta} r_{i,t}(\theta) \cdot \hat{A}_{i,t} \quad (54)$$

مشتق نسبت اهمیت $\nabla_{\theta} r_{i,t}(\theta)$ بر اساس قاعده مشتق لگاریتمی برابر است با:

$$\nabla_{\theta} r_{i,t}(\theta) = \frac{\nabla_{\theta} \pi_{\theta}(y_{i,t} \mid q, y_{i,<t})}{\pi_{\theta_{\text{old}}}(y_{i,t} \mid q, y_{i,<t})} = r_{i,t}(\theta) \nabla_{\theta} \log \pi_{\theta}(y_{i,t} \mid q, y_{i,<t}) \quad (55)$$

مشتق اول تابع دروازه‌بندی $f'_{i,t}(x)$ نسبت به x :

$$f'_{i,t}(x) = \frac{4}{\tau_{i,t}} \cdot \frac{d}{dx} [\sigma(\tau_{i,t}(x - 1))] = \frac{4}{\tau_{i,t}} \cdot \tau_{i,t} \cdot \sigma'(\tau_{i,t}(x - 1)) = 4\sigma'(\tau_{i,t}(x - 1)) \quad (56)$$

با توجه به اتحاد مشتق تابع سیگموئید $\sigma'(u) = \sigma(u)(1 - \sigma(u))$ ، اگر $p_{i,t}(\theta) \triangleq \sigma(\tau_{i,t}(r_{i,t}(\theta) - 1))$ تعریف شود:

$$w_{i,t}(\theta) \triangleq f'_{i,t}(r_{i,t}(\theta)) = 4p_{i,t}(\theta)(1 - p_{i,t}(\theta)) \quad (57)$$

با استفاده از تعاریف توابع هذلولوی و رابطه $\frac{1}{(e^{u/2} + e^{-u/2})^2} = \frac{1}{4 \cosh^2(u/2)} = \frac{1}{4} \text{sech}^2(u/2)$ ، وزن گرادیان برابر می‌شود با:

$$w_{i,t}(\theta) = 4 \cdot \frac{1}{4} \text{sech}^2\left(\frac{\tau_{i,t}}{2}(r_{i,t}(\theta) - 1)\right) = \text{sech}^2\left(\frac{\tau_{i,t}}{2}(r_{i,t}(\theta) - 1)\right) \quad (58)$$

بنابراین، فرم نهایی گرادیان خط‌مشی به دست می‌آید:

$$\nabla_{\theta} J_{\text{SAPO}}(\theta) = \mathbb{E} \left[\frac{1}{G} \sum_{i=1}^G \frac{1}{|y_i|} \sum_{t=1}^{|y_i|} w_{i,t}(\theta) r_{i,t}(\theta) \nabla_{\theta} \log \pi_{\theta}(y_{i,t} \mid q, y_{i,<t}) \hat{A}_{i,t} \right] \quad (59)$$

اثبات حفظ رفتار روی خطمشی (On-Policy Consistency): در نقطه روی خطمشی که $r_{i,t}(\theta) = 1$ است:

$$p_{i,t} = \sigma(0) = \frac{1}{2} \implies w_{i,t} = 4 \left(\frac{1}{2} \right) \left(\frac{1}{2} \right) = 1 \quad (۶۰)$$

این نتیجه اثبات می‌کند که در نقطه تعادل، گرادیان نرم SAPO دقیقاً برابر با گرادیان خطمشی بدون برش $r_{i,t} \hat{A}_{i,t} \nabla_{\theta} \log \pi_{\theta}$ است و ضریب $\frac{4}{\tau_{i,t}}$ در تعریف اولیه تابع $f_{i,t}$ دقیقاً جهت تضمین این شرط مقیاس‌گذاری شده است.

تحلیل گرادیان لاجیت‌ها و اثبات ضرورت دمای نامتقارن ($\tau_{\text{neg}} > \tau_{\text{pos}}$)

برای درک علت برتری دمای نامتقارن، انتشار گرادیان در لایه خروجی لاجیت‌ها $\mathbf{z} = [z_1, \dots, z_{|V|}]^T \in \mathbb{R}^{|V|}$ (با اندازه دایره واژگان $|V|$) را تحلیل می‌کنیم. توزیع احتمال توکن‌ها با تابع بیشینه هموار (Softmax) محاسبه می‌شود: $\pi_{\theta}(v) = \frac{e^{z_v}}{\sum_k e^{z_k}}$.

مشتق جزئی تابع اتلاف نسبت به لاجیت دلخواه z_v برابر است با:

$$\frac{\partial [\log \pi_{\theta}(y_{i,t}) \hat{A}_{i,t}]}{\partial z_v} = \frac{\hat{A}_{i,t}}{\pi_{\theta}(y_{i,t})} \cdot \frac{\partial \pi_{\theta}(y_{i,t})}{\partial z_v} \quad (۶۱)$$

بر اساس ماتریس ژاکوبی تابع Softmax:

$$\text{توکن نمونه‌برداری شده: } v = y_{i,t} \quad \frac{\partial \pi_{\theta}(y_{i,t})}{\partial z_{y_{i,t}}} = \pi_{\theta}(y_{i,t}) (1 - \pi_{\theta}(y_{i,t})) \quad (۶۲)$$

$$\text{سایر توکن‌ها: } v \neq y_{i,t} \quad \frac{\partial \pi_{\theta}(y_{i,t})}{\partial z_v} = -\pi_{\theta}(y_{i,t}) \pi_{\theta}(v) \quad (۶۳)$$

با جایگذاری روابط فوق در رابطه (۶۱)، گرادیان لاجیت‌ها حاصل می‌شود:

$$\frac{\partial \mathcal{L}_{i,t}}{\partial z_v} = \begin{cases} (1 - \pi_{\theta}(y_{i,t})) \hat{A}_{i,t} & \text{if } v = y_{i,t} \quad (\text{Sampled Token}) \\ -\pi_{\theta}(v) \hat{A}_{i,t} & \text{if } v \neq y_{i,t} \quad (\text{Unsampled Tokens}) \end{cases} \quad (۶۴)$$

تحلیل تئوریک رفتار نامتقارن:

- **در شرایط مزیت مثبت ($\hat{A}_{i,t} > 0$):** لاجیت توکن نمونه‌برداری شده افزایش یافته و لاجیت تمامی توکن‌های دیگر با ضریب $-\pi_{\theta}(v) \hat{A}_{i,t} < 0$ به آرامی کاهش می‌یابد. این فرآیند ذاتاً همگرا و متمرکز است.

- **در شرایط مزیت منفی ($\hat{A}_{i,t} < 0$):** لاجیت توکن نمونه‌برداری شده کاهش می‌یابد؛ اما برای تمامی $|V| - 1$ توکن دیگر، مقدار $-\pi_{\theta}(v) \hat{A}_{i,t} > 0$ مثبت می‌شود! یعنی لاجیت صدها هزار توکن نامربوط به طور همزمان افزایش می‌یابد. این پدیده باعث پخش نویز گرادیان شدید در دایره واژگان بزرگ شده و عامل اصلی ناپایداری آموزش است.

SAPO با تنظیم $\tau_{\text{neg}} > \tau_{\text{pos}}$ ، نرخ تضعیف گرادیان برای نمونه‌های با مزیت منفی را سریع‌تر می‌کند و بدین ترتیب نویز مخرب ناشی از انتشار مزیت منفی را مهار می‌نماید.

چارچوب یکپارچه سوروگیت و اثبات همگرایی به دروازه توالی (SAPO-GSPO اتصال)

فرض‌های تحلیلی:

- فرض A1 (گام‌های کوچک و نزدیکی به خط‌مشی): $r_{i,t}(\theta) \approx 1 \implies \log r_{i,t}(\theta) \approx r_{i,t}(\theta) - 1$
- فرض A2 (پراکندگی پایین درون توالی): با تعریف $z_{i,t} \triangleq \log r_{i,t}(\theta)$ و میانگین $\mu_i \triangleq \frac{1}{|y_i|} \sum_t z_{i,t}$ ، واریانس درون توالی $\text{Var}_i(\theta) \triangleq \frac{1}{|y_i|} \sum_t (z_{i,t} - \mu_i)^2$ برای اکثر توالی‌ها مقداری بسیار کوچک است.

تحت فرض A1 داریم $f'_{i,t}(r_{i,t}) = \text{sech}^2\left(\frac{\tau_i}{2}(r_{i,t} - 1)\right) \approx \text{sech}^2\left(\frac{\tau_i}{2} \log r_{i,t}\right) = g_{\tau_i}(z_{i,t})$ که در آن $g_{\tau}(z) \triangleq \text{sech}^2\left(\frac{\tau}{2}z\right)$ است.

با نوشتن بسط تیلور مرتبه دوم تابع $g_{\tau_i}(z_{i,t})$ حول نقطه میانگین $\mu_i = \log s_i(\theta)$:

$$g_{\tau_i}(z_{i,t}) = g_{\tau_i}(\mu_i) + g'_{\tau_i}(\mu_i)(z_{i,t} - \mu_i) + \frac{1}{2}g''_{\tau_i}(\xi_{i,t})(z_{i,t} - \mu_i)^2 \quad (65)$$

با میانگین‌گیری روی تمام توکن‌های توالی، جمله خطی اول دقیقاً صفر می‌شود:

$$\frac{1}{|y_i|} \sum_{t=1}^{|y_i|} g_{\tau_i}(z_{i,t}) = g_{\tau_i}(\mu_i) + \frac{1}{2|y_i|} \sum_{t=1}^{|y_i|} g''_{\tau_i}(\xi_{i,t})(z_{i,t} - \mu_i)^2 \quad (66)$$

با محاسبه مشتق دوم $g_{\tau}(z) = \text{sech}^2(\alpha z)$ با $\alpha = \frac{\tau}{2}$:

$$g''_{\tau}(z) = \alpha^2(4\text{sech}^2(\alpha z) - 6\text{sech}^4(\alpha z)) \implies \sup_z |g''_{\tau}(z)| = 2\alpha^2 = \frac{\tau^2}{2} \quad (67)$$

بنابراین، کران یکنواخت اختلاف میانگین دروازه توکن‌ها و دروازه توالی $D_i(\theta)$ حاصل می‌شود:

$$D_i(\theta) \triangleq \left| \frac{1}{|y_i|} \sum_{t=1}^{|y_i|} g_{\tau_i}(z_{i,t}) - g_{\tau_i}(\log s_i(\theta)) \right| \leq \frac{1}{2} \sup_z |g''_{\tau_i}(z)| \text{Var}_i(\theta) = \frac{\tau_i^2}{4} \text{Var}_i(\theta) \quad (68)$$

از آنجا که $D_i(\theta) \approx 0$ است، گرادیان SAPO به فرم سطح توالی تقلیل می‌یابد:

$$\nabla_{\theta} J_{\text{SAPO}}(\theta) \approx \mathbb{E} \left[\frac{1}{G} \sum_{i=1}^G \text{sech}^2\left(\frac{\tau_i}{2} \log s_i(\theta)\right) \nabla_{\theta} \log s_i(\theta) \hat{A}_i \right] \quad (69)$$

این اثبات نشان می‌دهد که SAPO در حالت عادی رفتاری کاملاً منسجم و هموار در سطح توالی (مشابه GSPO) دارد، اما در برخورد با توکن‌های پرت، به جای قطع کل گرادیان توالی، تنها توکن خطاکار را تضعیف می‌کند.

تحلیل‌های تئوری اطلاعات، آمار و دینامیک‌های ناحیه اطمینان

بر اساس بسط تیلور مرتبه دوم واگرایی کولبک-لایبیلر موضعی در سطح توکن:


$$D_{\text{KL}}(\pi_{\theta_{\text{old}}} \parallel \pi_{\theta}) \approx \frac{1}{2} \mathbb{E} [(\log r_{i,t}(\theta))^2] \quad (70)$$

در روش‌های برش سخت (GRPO و GSPO)، تابع جریمه در مرزهای برش دارای ناپیوستگی در مشتق اول است که شوک‌های بهینه‌سازی ایجاد می‌کند. در مقابل، تابع دروازه‌بندی SAPO از رده توابع بی‌نهایت بار مشتق‌پذیر (C^{∞}) بوده و یک ناحیه اطمینان پیوسته را شکل می‌دهد.

بررسی‌های تجربی روی بیش از 10^5 توالی و 10^9 توکن نشان می‌دهد که توزیع واریانس درون توالی $\text{Var}_i(\theta)$ در مدل‌های متراکم (Dense) نظیر Qwen3-4B کمتر از 0.005 و در مدل‌های ترکیبی از متخصصان (MoE) نظیر Qwen3-30B-A3B کمتر از 0.020 است. در هر دو حالت کران خطا $D_i(\theta) \leq \frac{\tau_i^2}{4} \text{Var}_i(\theta)$ زیر 0.005 باقی مانده و تقلیل تئوریک را به طور کامل در عمل پشتیبانی می‌کند.

دیاگرام معماری و جریان داده‌های الگوریتم

شکل ۵: ساختار پردازش داده، ارزیابی گروهی، اعمال دمای نامتقارن، دروازه‌بندی نرم و به‌روزرسانی پارامترها در الگوریتم SAPO را نمایش می‌دهد.



شکل ۵: دیاگرام جامع جریان داده، انتخاب دمای نامتقارن، دروازه‌بندی نرم و بهینه‌سازی خط‌مشی در الگوریتم SAPO.

شبکه الگوریتم SAPO

شبکه استاندارد پیاده‌سازی بهینه‌سازی خط‌مشی تطبیقی نرم در الگوریتم ۵ ارائه شده است.

Algorithm 5 Soft Adaptive Policy Optimization (SAPO)

```

1: Input: Policy parameters  $\theta_0$ , behavior policy checkpoint  $\theta_{\text{old}} = \theta_0$ , prompt dataset  $\mathcal{D}$ , group size  $G$ , learning rate  $\eta$ , positive temperature  $\tau_{\text{pos}}$ , negative temperature  $\tau_{\text{neg}}$ , number of mini-batches  $M$ , epochs  $K$ .
2: for iteration = 1, 2, ...,  $N_{\text{iters}}$  do
3:   Sample a batch of queries  $\{q_1, q_2, \dots, q_B\} \sim \mathcal{D}$ .
4:   Initialize rollout storage buffer  $\mathcal{B}_{\text{rollout}} \leftarrow \emptyset$ .
5:   for each query  $q \in \{q_1, \dots, q_B\}$  do
6:     Sample  $G$  responses  $\{y_1, \dots, y_G\} \sim \pi_{\theta_{\text{old}}}(\cdot | q)$ .
7:     Compute rewards  $\{R_1, \dots, R_G\}$  via task-specific environment/verifier.
8:     Compute mean  $\mu_R = \frac{1}{G} \sum_{j=1}^G R_j$  and std  $\sigma_R = \sqrt{\frac{1}{G} \sum_{j=1}^G (R_j - \mu_R)^2} + 10^{-8}$ .
9:     for  $i = 1, \dots, G$  do
10:      Compute group-normalized advantage:  $\hat{A}_i = (R_i - \mu_R) / \sigma_R$ .
11:      Store cached old log-probabilities  $\{\log \pi_{\theta_{\text{old}}}(y_{i,t} | q, y_{i,<t})\}_{t=1}^{|y_i|}$ .
12:      Append tuple  $(q, y_i, \hat{A}_i, \{\log \pi_{\theta_{\text{old}}}(y_{i,t})\}_{t=1}^{|y_i|})$  to  $\mathcal{B}_{\text{rollout}}$ .
13:    end for
14:  end for
15:  Partition  $\mathcal{B}_{\text{rollout}}$  into  $M$  disjoint mini-batches  $\{\mathcal{M}_1, \dots, \mathcal{M}_M\}$ .
16:  for epoch = 1, ...,  $K$  do
17:    for each mini-batch  $\mathcal{M}_b$  do
18:      Initialize mini-batch loss:  $\mathcal{L}_{\text{mini}}(\theta) \leftarrow 0$ .
19:      for each sample  $(q, y_i, \hat{A}_i, \text{log-probs}) \in \mathcal{M}_b$  do
20:        Select asymmetric temperature:  $\tau_i \leftarrow \tau_{\text{pos}}$  if  $\hat{A}_i > 0$  else  $\tau_{\text{neg}}$ .
21:        Compute current log-probabilities  $\{\log \pi_{\theta}(y_{i,t} | q, y_{i,<t})\}_{t=1}^{|y_i|}$ .
22:        Initialize sequence objective:  $\mathcal{L}_{\text{seq}} \leftarrow 0$ .
23:        for  $t = 1, \dots, |y_i|$  do
24:          Compute token ratio:  $r_{i,t}(\theta) = \exp(\log \pi_{\theta}(y_{i,t}) - \log \pi_{\theta_{\text{old}}}(y_{i,t}))$ .
25:          Compute soft gate:  $f_{i,t}(r_{i,t}) = \frac{4}{\tau_i} \cdot \sigma(\tau_i(r_{i,t}(\theta) - 1))$ .
26:           $\mathcal{L}_{\text{seq}} \leftarrow \mathcal{L}_{\text{seq}} + f_{i,t}(r_{i,t}(\theta)) \cdot \hat{A}_i$ .
27:        end for
28:         $\mathcal{L}_{\text{mini}}(\theta) \leftarrow \mathcal{L}_{\text{mini}}(\theta) - \frac{1}{|y_i|} \mathcal{L}_{\text{seq}}$ .
29:      end for
30:      Update parameters:  $\theta \leftarrow \theta - \eta \cdot \nabla_{\theta} \left( \frac{1}{|\mathcal{M}_b|} \mathcal{L}_{\text{mini}}(\theta) \right)$ .
31:    end for
32:  end for
33:  Synchronize behavior policy checkpoint:  $\theta_{\text{old}} \leftarrow \theta$ .
34: end for

```

نتایج تجربی و ارزیابی بنچمارک‌ها

عملکرد الگوریتم SAPO در مقایسه با GRPO-R2 و GSPO روی مدل استدلال گر Qwen3-30B-A3B-Base در جدول ۱۳ خلاصه شده است.

تحلیل ابلیشن دمای نامتقارن (τ_{neg} در برابر τ_{pos}): جدول ۱۴ تأثیر تنظیم دماهای مختلف را نشان می‌دهد. بر اساس این نتایج، تعیین دمای بالاتر برای توکن‌های با مزیت منفی ($\tau_{\text{neg}} > \tau_{\text{pos}}$) نقش حیاتی در جلوگیری از انحرافات گرادینانی و تثبیت آموزش ایفا می‌کند.

آموزش مدل‌های چندوجهی (Qwen3-VL): در ارزیابی‌های مقیاس بزرگ روی سری مدل‌های چندوجهی Qwen3-VL-30B-A3B در چهار بنچمارک چندوجهی و متنی شامل AIME25 (با ۳۲ نمونه)، Live-

جدول ۱۳: مقایسه عملکرد نهایی و پایداری در بنچمارک‌های استدلال ریاضی (Pass@1 روی ۱۶ نمونه) [۵۱].

الگوریتم	AIME 2025	HMMT 2025	BeyondAIME	وضعیت پایداری آموزش
GRPO-R2 [۵۲، ۳۲]	۵٪.۷۶	۰٪.۵۷	۵٪.۵۱	سقوط در گام ۷۵۰ (Collapse)
GSPO [۵۲]	۰٪.۷۹	۰٪.۶۱	۰٪.۵۴	سقوط در گام ۱۲۵۰ (Collapse)
SAPO (پیشنهادی)	۲٪.۸۲	۵٪.۶۴	۸٪.۵۸	کاملاً پایدار (1750 > گام)

جدول ۱۴: تحلیل ابلیشن تنظیمات دما در الگوریتم SAPO روی مدل Qwen3-30B-A3B [۵۱].

پیکربندی دما	مقادیر	دقت در AIME25	دینامیک آموزش
$\tau_{neg} < \tau_{pos}$	$\tau_{neg} = 0.95, \tau_{pos} = 1.00$	۰٪.۷۱	ناپایداری بسیار شدید و سقوط زودهنگام
$\tau_{neg} = \tau_{pos}$	$\tau_{neg} = 1.00, \tau_{pos} = 1.00$	۵٪.۷۸	پایداری متوسط با افت‌های مقطعی
$\tau_{neg} > \tau_{pos}$ (اصلی)	$\tau_{neg} = 1.05, \tau_{pos} = 1.00$	۲٪.۸۲	بالاترین پایداری و رشد پیوسته

CodeBench v6 [۵۵] (با ۸ نمونه)، ZebraLogic [۵۶] و MathVision [۵۷]، الگوریتم SAPO تحت بودجه محاسباتی یکسان موفق شد به امتیاز اعتبارسنجی تجمیعی ۷۶.۰ دست یابد و با اختلاف معنادار از GSPO (با امتیاز ۷۴۵.۰) و GRPO-R2 (با امتیاز ۷۳۸.۰) پیشی بگیرد.

جمع‌بندی

الگوریتم SAPO با جایگزین کردن برش سخت ناپیوسته با یک ناحیه اطمینان نرم (sech^2) و اعمال مکانیزم تنظیم دمای نامتقارن برای مهار نویز گرادینت‌های منفی، پایداری بهینه‌سازی خط‌مشی را متحول ساخته است. این الگوریتم بدون نیاز به سازوکارهای پرهزینه نظیر بازپخش مسیریابی (Routing Replay) در مدل‌های MoE، بالاترین دقت و بهره‌وری داده را به نمایش گذاشته و به عنوان چارچوبی استاندارد برای آموزش مدل‌های پیشرفته نسل جدید زبانی و چندوجهی شناخته می‌شود.

• sda

• sda

• sda

- [1] Houyi Li, Wenzhen Zheng, Qiufeng Wang, Zhenyu Ding, Haoying Wang, Zili Wang, Shijie Xuyang, Ning Ding, Shuigeng Zhou, Xiangyu Zhang, et al. Predictable scale: Part ii, farseer—a refined scaling law in large language models. *arXiv preprint arXiv:2506.10972*, 2025.
- [2] Zhengyu Chen, Siqi Wang, Teng Xiao, Yudong Wang, Shiqi Chen, Xunliang Cai, Junxian He, and Jingang Wang. Revisiting scaling laws for language models: The role of data quality and training strategies. *arXiv preprint*, 2025.
- [3] Sean McLeish, John Kirchenbauer, David Yu Miller, Siddharth Singh, Abhinav Bhatele, Micah Goldblum, Ashwinee Panda, and Tom Goldstein. Gemstones: A model suite for multi-faceted scaling laws. *arXiv preprint arXiv:2502.06857*, 2025.
- [4] Song Bian, Tao Yu, Shivaram Venkataraman, and Youngsuk Park. Scaling laws meet model architecture: Toward inference-efficient llms. *arXiv preprint arXiv:2510.18245*, 2025.
- [5] Yizhou Liu, Sara Kangaslahti, Ziming Liu, and Jeff Gore. Inverse depth scaling from most layers being similar. *arXiv preprint arXiv:2602.05970*, 2026.
- [6] Wenjie Sun, Jinning Yang, Shuai Zhang, and Mengnan Du. Law of neural interaction: Depth–width shape, interaction efficiency, and generalization. *arXiv preprint arXiv:2605.27989*, 2026.
- [7] Nandan Kumar Jha and Brandon Reagan. Spectral scaling laws in language models: How effectively do feed-forward networks use their latent space? *arXiv preprint arXiv:2510.00537*, 2025.
- [8] Maximilian Beck, Kajetan Schweighofer, Sebastian Böck, Sebastian Lehner, and Sepp Hochreiter. xlstm scaling laws: Competitive performance with linear time-complexity. *arXiv preprint arXiv:2510.02228*, 2026.
- [9] Anonymous. On the recall scaling laws in mamba: A theoretical and mechanistic study via hashing. *arXiv preprint*, 2026.
- [10] Changxin Tian, Kunlong Chen, Jia Liu, Ziqi Liu, Zhiqiang Zhang, and Jun Zhou. Towards greater leverage: Scaling laws for efficient mixture-of-experts language models. *arXiv preprint arXiv:2507.17702*, 2025.
- [11] Samira Abnar, Harshay Shah, Dan Busbridge, Alaaeldin El-Nouby, Josh Susskind, and Vimal Thilak. Parameters vs flops: Scaling laws for optimal sparsity for mixture-of-experts language models. *arXiv preprint arXiv:2501.12370*, 2025.
- [12] Jan Ludziejewski, Maciej Pióro, Jakub Krajewski, Maciej Stefaniak, Michał Krutul, Jan Małaśnicki, Marek Cygan, Piotr Sankowski, Kamil Adamczewski, Piotr Miłoś, et al. Joint moe scaling laws: Mixture of experts can be memory efficient. *arXiv preprint arXiv:2502.05172*, 2025.
- [13] Seng Pei Liew, Takuya Kato, and Sho Takase. Scaling laws for upcycling mixture-of-experts language models. *arXiv preprint arXiv:2502.03009*, 2025.

- [14] Anirudh Subramanyam, Yuxin Chen, and Robert L Grossman. Scaling laws revisited: Modeling the role of data quality in language model pretraining. *arXiv preprint arXiv:2510.03313*, 2026.
- [15] Mustafa Shukor, Louis Bethune, Dan Busbridge, David Grangier, Enrico Fini, Alaaeldin El-Nouby, and Pierre Ablin. Scaling laws for optimal data mixtures. *arXiv preprint arXiv:2507.09404*, 2025.
- [16] Francesco Cagnetta, Alessandro Favero, Antonio Sclocchi, and Matthieu Wyart. Scaling laws and representation learning in simple hierarchical languages: Transformers vs. convolutional architectures. *arXiv preprint arXiv:2505.07070*, 2025.
- [17] William Held, David Hall, Percy Liang, and Diyi Yang. Relative scaling laws for llms. *arXiv preprint arXiv:2510.24626*, 2026.
- [18] Baoqing Yue, Jinyuan Zhou, Zixi Wei, Jingtao Zhan, Qingyao Ai, and Yiqun Liu. Relative-based scaling law for neural language models. *arXiv preprint arXiv:2510.20387*, 2025.
- [19] Chaojun Xiao, Jie Cai, Weilin Zhao, Biyuan Lin, Guoyang Zeng, Jie Zhou, Zhi Zheng, Xu Han, Zhiyuan Liu, and Maosong Sun. Densing law of llms. *Nature Machine Intelligence*, pages 1–11, 2025.
- [20] John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford, and Oleg Klimov. Proximal policy optimization algorithms. *arXiv preprint arXiv:1707.06347*, 2017.
- [21] Volodymyr Mnih, Koray Kavukcuoglu, David Silver, Andrei A Rusu, Joel Veness, Marc G Bellemare, Alex Graves, Martin Riedmiller, Andreas K Fidjeland, Georg Ostrovski, et al. Human-level control through deep reinforcement learning. *Nature*, 518(7540):529–533, 2015.
- [22] Marc G Bellemare, Yavar Naddaf, Joel Veness, and Michael Bowling. The arcade learning environment: An evaluation platform for general agents. *Twenty-Fourth International Joint Conference on Artificial Intelligence (IJCAI)*, 2015.
- [23] Greg Brockman, Vicki Cheung, Ludwig Pettersson, Jonas Schneider, John Schulman, Jie Tang, and Wojciech Zaremba. Openai gym. *arXiv preprint arXiv:1606.01540*, 2016.
- [24] Yan Duan, Xi Chen, Rein Houthoofd, John Schulman, and Pieter Abbeel. Benchmarking deep reinforcement learning for continuous control. *International Conference on Machine Learning (ICML)*, pages 1329–1338, 2016.
- [25] Ronald J Williams. Simple statistical gradient-following algorithms for connectionist reinforcement learning. *Machine Learning*, 8(3-4):229–256, 1992.
- [26] Volodymyr Mnih, Adria Puigdomenech Badia, Mehdi Mirza, Alex Graves, Timothy Lillicrap, Tim Harley, David Silver, and Koray Kavukcuoglu. Asynchronous methods for deep reinforcement learning. *International Conference on Machine Learning (ICML)*, pages 1928–1937, 2016.
- [27] Sham Kakade and John Langford. Approximately optimal approximate reinforcement learning. *International Conference on Machine Learning (ICML)*, 2:267–274, 2002.
- [28] John Schulman, Sergey Levine, Philipp Moritz, Michael Jordan, and Pieter Abbeel. Trust region policy optimization. *International Conference on Machine Learning (ICML)*, pages 1889–1897, 2015.
- [29] Diederik P Kingma and Jimmy Ba. Adam: A method for stochastic optimization. *arXiv preprint arXiv:1412.6980*, 2014.

-
- [30] John Schulman, Philipp Moritz, Sergey Levine, Michael Jordan, and Pieter Abbeel. High-dimensional continuous control using generalized advantage estimation. *arXiv preprint arXiv:1506.02438*, 2015.
 - [31] Nicolas Heess, Srinivasan Sriram, Jay Lemmon, Josh Merel, Greg Wayne, Yuval Tassa, Tom Erez, Ziyu Wang, SM Eslami, Martin Riedmiller, et al. Emergence of locomotion behaviours in rich environments. *arXiv preprint arXiv:1707.02286*, 2017.
 - [32] Zhihong Shao, Peiyi Wang, Qihao Zhu, Runxin Xu, Junxiao Song, Xiao Bi, Haowei Zhang, Mingchuan Zhang, Y. K. Li, Y. Wu, and Daya Guo. Deepseekmath: Pushing the limits of mathematical reasoning in open language models. *arXiv preprint arXiv:2402.03300*, 2024.
 - [33] Long Ouyang, Jeffrey Wu, Xu Jiang, Diogo Almeida, Carroll Wainwright, Pamela Mishkin, Chong Zhang, Sandhini Agarwal, Katarina Slama, Alex Ray, et al. Training language models to follow instructions with human feedback. *Advances in Neural Information Processing Systems*, 35:27730–27744, 2022.
 - [34] John Schulman. Approximating kl divergence. *Online blog: <http://joschu.net/blog/kl-approx.html>*, 2020.
 - [35] Hunter Lightman, Vineet Kosaraju, Yura Burda, Harri Edwards, Bowen Baker, Teddy Lee, Jan Leike, John Schulman, Ilya Sutskever, and Karl Cobbe. Let’s verify step by step. *arXiv preprint arXiv:2305.20050*, 2023.
 - [36] Peiyi Wang, Lei Li, Zhihong Shao, Runxin Xu, Damai Dai, Yifei Li, Deyu Chen, Y Wu, and Zhifang Sui. Math-shepherd: Verify and reinforce llms step-by-step without human annotations. *arXiv preprint arXiv:2312.08935*, 2023.
 - [37] Zheng Yuan, Hongyi Yuan, Chengpeng Li, Guanting Dong, Chuanqi Tan, and Chang Zhou. Scaling relationship on learning mathematical reasoning with large language models. *arXiv preprint arXiv:2308.01825*, 2023.
 - [38] Rafael Rafailov, Archit Sharma, Eric Mitchell, Stefano Ermon, Christopher D Manning, and Chelsea Finn. Direct preference optimization: Your language model is secretly a reward model. *Advances in Neural Information Processing Systems*, 36, 2023.
 - [39] Chujie Zheng, Shixuan Liu, Mingze Li, Xiong-Hui Chen, Bowen Yu, Chang Gao, Kai Dang, Yuqiong Liu, Rui Men, An Yang, Jingren Zhou, and Junyang Lin. Group sequence policy optimization. *arXiv preprint arXiv:2507.18071*, 2025.
 - [40] Team Qwen. Qwen3 technical report. *arXiv preprint arXiv:2505.09388*, 2025.
 - [41] Team Qwen. Qwq-32b: Embracing the power of reinforcement learning. <https://qwenlm.github.io/blog/qwq-32b/>, 2025.
 - [42] OpenAI. Learning to reason with llms. <https://openai.com/index/learning-to-reason-with-llms/>, 2024.
 - [43] DeepSeek-AI. Deepseek-r1: Incentivizing reasoning capability in llms via reinforcement learning. *arXiv preprint arXiv:2501.12948*, 2025.
 - [44] MiniMax. Minimax-m1: Scaling test-time compute efficiently with lightning attention. *arXiv preprint arXiv:2506.13585*, 2025.
-

- [45] Chujie Zheng, Pei Ke, Zheng Zhang, and Minlie Huang. Click: Controllable text generation with sequence likelihood contrastive learning. In *Findings of the Association for Computational Linguistics: ACL 2023*, pages 65–78, 2023.
- [46] Qiying Yu, Zheng Zhang, Ruofei Zhu, Yufeng Yuan, Xiaochen Zuo, Yu Yue, Weinan Dai, Tiantian Fan, Gaohong Liu, Juncai Liu, et al. Dapo: An open-source llm reinforcement learning system at scale. *arXiv preprint arXiv:2503.14476*, 2025.
- [47] An Yang, Baosong Yang, Beichen Zhang, Binyuan Hui, Bo Zheng, Bowen Yu, Chengyuan Li, Dayiheng Liu, Fei Huang, Haoran Wei, et al. Qwen2.5 technical report. *arXiv preprint arXiv:2412.15115*, 2024.
- [48] Daya Guo, Dejian Yang, Haowei Zhang, Junxiao Song, Ruoyu Zhang, Runxin Xu, Qihao Zhu, Shirong Ma, Peiyi Wang, Xiao Bi, et al. Deepseek-r1: Incentivizing reasoning capability in llms via reinforcement learning. *arXiv preprint arXiv:2501.12948*, 2025.
- [49] Guangming Sheng, Chi Zhang, Zilingfeng Ye, Xibin Wu, Wang Zhang, Ru Zhang, Yanghua Peng, Haibin Lin, and Chuan Wu. Hybridflow: A flexible and efficient rlhf framework. *arXiv preprint arXiv:2409.19256*, 2024.
- [50] Ilya Loshchilov and Frank Hutter. Decoupled weight decay regularization. In *International Conference on Learning Representations (ICLR)*, 2019.
- [51] Chang Gao, Chujie Zheng, Xiong-Hui Chen, Kai Dang, Shixuan Liu, Bowen Yu, An Yang, Shuai Bai, Jingren Zhou, and Junyang Lin. Soft adaptive policy optimization. *arXiv preprint arXiv:2511.20347*, 2025.
- [52] Chujie Zheng, Shixuan Liu, Mingze Li, Xiong-Hui Chen, Bowen Yu, Chang Gao, Kai Dang, Yuqiong Liu, Rui Men, An Yang, et al. Group sequence policy optimization. *arXiv preprint arXiv:2507.18071*, 2025.
- [53] DeepSeek-AI. Deepseek-r1: Incentivizing reasoning capability in llms via reinforcement learning. *arXiv preprint arXiv:2501.12948*, 2025.
- [54] Team Qwen. Qwen3 technical report. *arXiv preprint arXiv:2505.09388*, 2025.
- [55] Naman Jain, King Han, Alex Gu, Wen-Ding Li, Fanjia Yan, Tianjun Zhang, Sida Wang, Armando Solar-Lezama, Koushik Sen, and Ion Stoica. Livecodebench: Holistic and contamination free evaluation of large language models for code. *arXiv preprint arXiv:2403.07974*, 2024.
- [56] Bill Yuchen Lin, Ronan Le Bras, Kyle Richardson, Ashish Sabharwal, Radha Poovendran, Peter Clark, and Yejin Choi. Zebralogic: On the scaling limits of llms for logical reasoning. *arXiv preprint arXiv:2502.01100*, 2025.
- [57] Ke Wang, Juntao Pan, Weikang Shi, Zimu Lu, Houxing Ren, Aojun Zhou, Mingjie Zhan, and Hongsheng Li. Measuring multimodal mathematical reasoning with math-vision dataset. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 37, pages 95095–95169, 2024.
- [58] Ziyu Wang, Victor Bapst, Nicolas Heess, Volodymyr Mnih, Remi Munos, Koray Kavukcuoglu, and Nando de Freitas. Sample efficient actor-critic with experience replay. *arXiv preprint arXiv:1611.01224*, 2016.

- [59] Xing Chen, Dongcui Diao, Hechang Chen, Hengshuai Yao, Haiyin Piao, Zhixiao Sun, Zhiwei Yang, Randy Goebel, Bei Jiang, and Yi Chang. The sufficiency of off-policyyness and soft clipping: Ppo is still insufficient according to an off-policy measure. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 37, pages 7078–7086, 2023.